

PEC 2 D.L.

Procesamiento del lenguaje natural

por Jaime Ciriaco Beaumont

En esta práctica de he trabajado con AG News para resolver una tarea de clasificación automática de noticias en cuatro categorías: World, Sports, Business y Sci/Tech. La idea no era solo entrenar modelos y sacar métricas, sino comparar enfoques distintos y ver qué gana y qué pierde cada uno en una tarea real de PLN.

El trabajo se ha organizado en cuatro bloques: análisis y preprocesamiento del texto, entrenamiento de modelos recurrentes, ajuste fino de modelos Transformer y una parte final de explicabilidad con mapas de atención. El objetivo final es terminar con una comparación razonada entre los modelos y no quedarse solo en los números.

1. Análisis y preprocesamiento de datos

Se ha utilizado AG News, que ya viene separado en entrenamiento y test. A partir del entrenamiento original se ha creado además un conjunto de validación, de forma que finalmente se ha trabajado con 108.000 noticias para train, 12.000 para validación y 7.600 para test. Esta separación me parecía importante porque la validación se ha usado para seguir la evolución del aprendizaje y ajustar los modelos, mientras que el test se ha dejado aislado para la comparación final.

Lo primero que revisé fue si el dataset estaba balanceado y cómo eran de largos los textos. En este caso el conjunto está equilibrado: en entrenamiento hay 27.000 noticias por clase. Además, la longitud media ronda las 37,8 palabras, con una mediana de 37. El 95% de los textos no supera las 53 palabras y el 99% llega a 70, así que no tenía sentido trabajar con secuencias exageradamente largas.




Figura 1. Distribución de clases y longitud de las noticias en el conjunto de entrenamiento.

Para los modelos recurrentes opté por una tokenización simple a nivel de palabra. El texto se pasó a minúsculas y se limpió de forma moderada, eliminando caracteres extraños pero sin hacer un preprocesado agresivo. La idea fue conservar la mayor parte de la información útil del texto sin complicar demasiado el pipeline. A partir del entrenamiento se construyó un vocabulario de 50.000 términos, y la longitud máxima para GRU y LSTM se fijó en 58 tokens, que está muy cerca del percentil 95 de la longitud real de las noticias. Para los Transformers la estrategia cambió: ahí no construí vocabulario propio, porque cada modelo ya trae su tokenizador preentrenado. En ese caso utilicé tokenización subword y una longitud máxima de 128 tokens, que me pareció un valor razonable para este corpus.

2. Modelado y comparativa

2.1. Modelo 1: GRU

Como primer modelo se entrenó una GRU bidireccional con embedding de 200 dimensiones, 256 unidades ocultas y dropout de 0,30. La elegí como línea base porque suele funcionar bien en clasificación de texto y, además, es algo más ligera que una LSTM. La convergencia fue buena y bastante estable: la pérdida de entrenamiento descendió con claridad y las métricas de validación se estabilizaron pronto en una zona alta.




Figura 2. Curvas de aprendizaje del modelo GRU.

En test, la GRU alcanzó una accuracy de 0,9176 y un F1 macro de 0,9176. Por clases, el mejor comportamiento apareció en Sports, mientras que las categorías más difíciles fueron Business y Sci/Tech. Esto tiene sentido porque precisamente son dos clases que se pisan bastante en el contenido real de las noticias.

2.2. Modelo 2: LSTM

El segundo modelo fue una LSTM con una estructura muy parecida a la de la GRU, para que la comparación fuese limpia: mismo embedding, mismo tamaño oculto y mismo dropout. La idea era comprobar si la memoria algo más rica de la LSTM se traducía en una mejora real. El resultado fue un empate casi total. La LSTM obtuvo 0,9170 de accuracy y 0,9167 de F1 macro, es decir, quedó prácticamente igual que la GRU, aunque ligeramente por debajo. Además, se activó early stopping antes de completar todas las épocas y seguir entrenando no estaba aportando una mejora clara.

2.3. Modelos 3 y 4: Transformers fine-tuned

Para los Transformers opté por lo recomendado, DistilBERT y BERT-base-uncased. La elección me parecía natural porque permiten comparar dos situaciones bastante representativas: por un lado, un modelo más ligero y eficiente; por otro, uno más grande y teóricamente más potente. En ambos casos se hizo fine-tuning específico para AG News. Los hiperparámetros principales fueron longitud máxima de 128 tokens, learning rate de $2e-5$, weight decay de 0,01, warmup ratio de 0,1, hasta 3 épocas y early stopping con paciencia 1.

DistilBERT alcanzó en test una accuracy de 0,9468 y un F1 macro de 0,9469. La convergencia fue muy rápida y las métricas de validación se mantuvieron muy estables desde las primeras evaluaciones. BERT-base-uncased obtuvo 0,9462 de accuracy y 0,9462 de F1 macro, es decir, prácticamente igual, aunque ligeramente por debajo y con un mayor coste computacional. En esta práctica concreta, el modelo más grande no ha compensado ese coste con una mejora real.




Figura 3. Curvas de aprendizaje de DistilBERT durante el fine-tuning.

Antes de comparar los resultados, conviene hacer un pequeño pero importante matiz: la mejora de los Transformers no viene solo de la arquitectura, sino también del tokenizador subword y del propio preentrenamiento. Por eso, la comparación debe interpretarse teniendo en cuenta que cada familia de modelos trabaja con la representación de entrada que mejor encaja con su diseño.

La comparación global deja una idea bastante clara: los Transformers superan a las arquitecturas recurrentes construidas desde cero, pero las recurrentes no quedan mal en absoluto. De hecho, tanto GRU como LSTM rondan 0,917 de F1 macro sobre el conjunto completo, que ya es un resultado muy sólido. Lo interesante es que DistilBERT y BERT-base suben hasta alrededor de 0,946, y ahí ya la diferencia es importante.

Modelo	Accuracy	Precision macro	Recall macro	F1 macro
DistilBERT	0,9468	0,9470	0,9468	0,9469
BERT-base	0,9462	0,9464	0,9462	0,9462
GRU	0,9176	0,9181	0,9176	0,9176
LSTM	0,9170	0,9171	0,9170	0,9167

Tabla 1. Métricas finales en el conjunto de test.




Figura 4. Comparativa global de los cuatro modelos usando F1 macro en test.

Si me quedo con una conclusión práctica, diría que DistilBERT es el mejor compromiso de toda la práctica. Rinde ligeramente mejor que BERT-base y, además, lo hace con un coste menor. Entre las recurrentes apenas hay distancia, así que ahí el criterio razonable sería quedarse con la GRU por simplicidad y por haber quedado un poco por encima.

3. Explicabilidad mediante atención

Para la parte de explicabilidad analicé el mejor Transformer de los dos entrenados, que en este caso fue DistilBERT. A partir del conjunto de test seleccioné ejemplos correctos e incorrectos y extraje pesos de atención para ver si el modelo parecía fijarse en palabras relevantes. No me interesaba solo enseñar mapas bonitos, sino comprobar si esos patrones ayudaban de verdad a entender por qué el modelo acertaba o fallaba.

Lo más interesante es que los errores no parecen aleatorios. En varios ejemplos fallidos se ve que el modelo presta mucha atención a términos que son relevantes, pero que empujan la noticia hacia una clase vecina. Por ejemplo, en noticias reales de Sci/Tech sobre IBM o Google, el modelo termina prediciendo Business, y eso tiene bastante sentido porque aparecen palabras muy asociadas al mundo empresarial o financiero. Algo parecido ocurre con noticias de World que incluyen términos económicos como oil market, que también acaban cayendo hacia Business.




Figura 5. Dos ejemplos de mapas de atención de la última capa en noticias mal clasificadas.

Lejos de parecerme un fallo sin sentido, esto me parece informativo. El modelo no confunde categorías al azar, sino precisamente en zonas donde las fronteras semánticas son difusas, sobre todo entre Business y Sci/Tech. En los ejemplos bien clasificados ocurre lo contrario: la atención se concentra en palabras claramente alineadas con el tema principal de la noticia. En conjunto, creo que los mapas de atención sí ofrecen una explicación plausible del comportamiento del modelo, aunque tampoco conviene tomarlos como una prueba absoluta de causalidad. Sirven para interpretar, pero no para explicar por completo todo el proceso de decisión.

4. Conclusiones

La conclusión principal de la práctica es que, para clasificación de noticias en AG News, los modelos Transformer ajustados mediante fine-tuning superan a las arquitecturas recurrentes construidas desde cero. Aun así, me parece importante destacar que las recurrentes siguen ofreciendo resultados muy competitivos: tanto GRU como LSTM se mueven alrededor de 0,917 de F1 macro, lo que ya indica una capacidad de generalización bastante alta.

Dentro de los Transformers, el hallazgo más interesante ha sido que DistilBERT ha quedado ligeramente por encima de BERT-base, pese a ser un modelo más ligero. Eso refuerza la idea de que no siempre compensa usar la arquitectura más grande disponible. En esta práctica concreta, DistilBERT me parece la mejor opción global porque ofrece el mejor equilibrio entre calidad y coste computacional.

También me parece importante lo que se extrae de la parte de atención. Los errores del modelo no son arbitrarios, sino que aparecen sobre todo en noticias donde las clases se pisan semánticamente o por intereses comunes o colaboraciones entre 2 medios, especialmente entre Business y Sci/Tech. Los mapas de atención muestran que el modelo suele fijarse en palabras razonables, aunque eso no siempre garantice una clasificación correcta cuando el contenido toca varios temas a la vez.

En conjunto, me quedo con tres ideas: que un preprocesado sencillo pero bien justificado puede ser suficiente, que los modelos preentrenados marcan una diferencia real en rendimiento, y que mirar solo la accuracy final se queda corto si no se acompaña de curvas, errores y análisis de atención.