

# Memoria PEC 2 C.E.

## Estrategias Evolutivas VS Evolución Diferencial

por Jaime Ciriaco Beaumont

### Introducción

En esta PEC trabajamos con optimización en continuo mediante dos familias de algoritmos evolutivos: Estrategias Evolutivas (EE) y Evolución Diferencial (DE). Al igual que en la actividad anterior, el enfoque es doble: Primero, implementar el esquema del algoritmo de forma fiel y segundo, evaluar experimentalmente su eficacia y eficiencia porque, al ser algoritmos estocásticos, una sola ejecución no es representativa.

El objetivo es minimizar dos funciones objetivo reales. Una de ellas es monomodal y la otra es multimodal, lo cual nos permite observar cómo cambian los operadores y parámetros cuando el paisaje de búsqueda es más o menos complicado.

## Descripción del problema: funciones objetivo

Se consideran dos funciones de prueba habituales en computación evolutiva. En ambos casos buscamos el mínimo global y trabajamos con dominios acotados o recorte al dominio tras la mutación/variación.

### 1) Función de Potencias Desplazada

Definición:

$$f(\mathbf{x}) = \sum_{i=1}^n |x_i - \theta|^{i+1}$$

Al elevar cada componente a una potencia distinta (2, 3, 4, ...) se penalizan de forma creciente las desviaciones en dimensiones de mayor índice. Es una función monomodal: tiene un único valle hacia el óptimo ( $x_i = \theta$ ). Dominio usado:  $-10 \leq x_i \leq 10$ .

### 2) Función de Ackley

Definición:


$$f(\mathbf{x}) = -20 \cdot \exp \left( -0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \right) - \exp \left( \frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i) \right) + 20 + e$$

Es una función multimodal: presenta oscilaciones (muchos mínimos locales) y un mínimo global alrededor del origen. Esto la hace interesante para comparar exploración vs explotación. Dominio usado:  $-32.77 \leq x_i \leq 32.77$ .


## Representación gráfica (n = 2)

Para visualizar el paisaje de búsqueda, se representan ambas funciones en 3D con  $n=2$ . Esto ayuda a entender por qué Ackley es más difícil (muchas ondulaciones al ser multimodal) frente a Potencias (valle único al ser monomodal):

Potencias desplazada (n=2, theta=5)



Ackley (n=2)



## Implementación

Siguiendo la misma filosofía que en el anterior ejercicio, se aplicó la implementación por etapas: representación, evaluación, operadores de variación y selección de supervivientes. El código base se concentra en el fichero `ee_de_base.py`, y la evaluación automatizada en `ee_de_evaluation.py`, para luego visualizar la comparación con `ee_de_mejores_config.py`.

### 1) Estrategias Evolutivas (EE)

En EE trabajamos con individuos reales  $x = (x_1, \dots, x_n)$  y con auto-adaptación del tamaño de paso  $\sigma$ . La idea es que cada individuo “aprenda” cuán grande debe ser su mutación.

**1a) Representación del individuo:** Cada individuo se almacena como un diccionario con: (1) vector real  $x$ , (2)  $\sigma$ , y (3) fitness. Se consideran dos variantes:

- `modo_sigma = "1"`: un único  $\sigma$  para todas las dimensiones, la mutación isótropa.
- `modo_sigma = "n"`: un  $\sigma$  por dimensión, la mutación anisótropa, útil si cada variable necesita escalas distintas.

**1b) Población inicial:** Se genera una población inicial de tamaño  $\mu$  ( $\mu=30$ ) con valores uniformes en el dominio. El  $\sigma$  inicial se fija según la función (0.3 en Potencias y 1.0 en Ackley), manteniendo el mismo valor para todos los individuos al comenzar. Esto es equivalente a partir sin conocimiento y dejar que la auto-adaptación lo ajuste.

**1c) Recombinación global:** Se aplican dos tipos de recombinación global, pues se usan todos los padres disponibles en la población:

- Recombinación discreta global: para cada componente se elige aleatoriamente el valor de uno de los padres.
- Recombinación intermedia promediada global: cada componente es el promedio de los padres, lo que suaviza el movimiento.

En ambos casos se recombina también  $\sigma$ , donde si es "1" se promedia o elige; si es "n" se hace componente a componente.

**1d) Mutación no correlacionada con auto-adaptación:** Tras recombinar, se muta con el esquema log-normal: primero se actualiza  $\sigma$  y después se perturba  $x$  con  $N(0,1)$ . Se usa  $\epsilon_0$ , `epsilon_sigma`, para evitar que  $\sigma$  colapse a 0.

Los parámetros  $\tau$  y  $\tau'$  se fijan con las recomendaciones habituales en función de  $n$ :  $\tau = 1/\sqrt{2 \cdot \sqrt{n}}$  y  $\tau' = 1/\sqrt{2 \cdot n}$ . Con esto no “inventamos” valores, sino que aplicamos una regla estándar dependiente de la dimensión.

**1e) Selección de supervivientes:** Se comparan dos estrategias:

- $(\mu, \lambda)$ : los supervivientes se eligen sólo entre los descendientes, lo cual implica mayor presión de renovación.
- $(\mu + \lambda)$ : los supervivientes se eligen entre padres + descendientes, siendo un método más elitista, conserva soluciones buenas.

En ambos casos se ordena por fitness y se conservan los  $\mu$  mejores.

## 2) Evolución Diferencial (DE)

En DE la población también son vectores reales, pero el operador principal no es una mutación gaussiana, sino una “mutación diferencial”: se suman y restan vectores de la población para generar un mutante. Después se hace cruce binomial y selección uno-a-uno.

**2a) Población inicial:** Se genera una población de tamaño  $NP=30$  uniforme en el dominio, igual que en EE. Cada individuo guarda su  $x$  y su fitness.

**2b) Mutación diferencial:** Se prueban dos variantes:

- $rand/1$ :  $v = x_{r1} + F \cdot (x_{r2} - x_{r3})$  la cual es una exploración más aleatoria.
- $best/1$ :  $v = x_{best} + F \cdot (x_{r1} - x_{r2})$  siendo una explotación más fuerte hacia el mejor actual.

El factor  $F$  controla la amplitud del salto. Valores grandes exploran más, pero pueden desestabilizar; valores moderados suelen ser más controlados.

**2c) Cruce binomial:** El trial  $u$  se forma componente a componente: con probabilidad  $CR$  se toma la componente del mutante  $v$  y, en caso contrario, la del objetivo. Se fuerza al menos una componente del mutante mediante  $j\_rand$  para evitar que  $u$  sea idéntico al objetivo.

**2d) Selección:** Si el trial mejora, básicamente, que el fitness sea menor o igual, reemplaza al objetivo. Esto hace que DE sea “elitista” de forma local: nunca empeora la población de forma directa, menos en el caso donde hubiera estancamiento.

## Metodología de evaluación

Como se especifica en el enunciado, el componente experimental es clave. Se realizan múltiples ejecuciones con semillas distintas y se calculan métricas para comparar configuraciones. Por esto ocurren la cantidad de csv entregados.

## Configuración común de experimentos

- Dimensión:  $n = 10$  (experimentos principales).
- Número de ejecuciones por configuración: 5.
- Máximo de generaciones:  $NG = 1200$ .
- Criterio de éxito:  $\text{fitness} \leq \varepsilon$ , con  $\varepsilon = 1e-6$ .
- Coste medido en número de evaluaciones de la función objetivo.
- Comparo EE y DE con el mismo presupuesto en nº de evaluaciones no por generaciones, por eso PEX es la métrica clave para eficiencia

Se registra un historial por generación con el mejor fitness y el contador de evaluaciones. Esto permite dibujar curvas de progreso y calcular PEX como la primera evaluación en la que se alcanza  $\varepsilon$ .

## Métricas (TE, VAMM, PEX)

Para cada configuración se calculan:

- TE (Tasa de Éxito): proporción de ejecuciones que alcanzan  $\text{fitness} \leq \varepsilon$ .
- VAMM: media del mejor fitness final, cuando termina la ejecución. Si  $TE=1$ , VAMM tiende a ser muy pequeño, como termina ocurriendo en todos los casos.
- PEX: número medio de evaluaciones necesarias hasta alcanzar  $\varepsilon$ , pero solo en ejecuciones exitosas.

Interpretación práctica: TE mide robustez, PEX mide eficiencia o cuánto cuesta llegar y VAMM da una idea de la calidad final, pero con  $\varepsilon$  muy exigente, VAMM suele ser extremadamente pequeño cuando hay éxito, además esto hace que VAMM discrimine poco aquí y PEX una vez más, es la clave de este entorno.

## Resultados experimentales

A continuación se muestran los resultados agregados de las 5 ejecuciones para las configuraciones probadas en EE y DE. En todos los casos se minimiza la función, por lo que valores menores son mejores.

### Resultados para EE

Se prueban 4 combinaciones clave:  $\text{modo\_sigma} \in \{ "1", "n" \}$ ,  $\text{recomb} \in \{ \text{discreta}, \text{intermedia} \}$  y  $\text{supervivencia} \in \{ (\mu, \lambda), (\mu + \lambda) \}$ .

EE – Potencias ( $n=10$ )

| modo sigma | recomb            | supervivencia | TE    | VAMM      | PEX   |
|------------|-------------------|---------------|-------|-----------|-------|
| 1          | discreta_global   | (mu,lambda)   | 1.000 | 6.433e-08 | 6030  |
| 1          | intermedia_global | (mu+lambda)   | 1.000 | 3.651e-09 | 8750  |
| n          | discreta_global   | (mu,lambda)   | 1.000 | 5.088e-27 | 5630  |
| n          | intermedia_global | (mu+lambda)   | 1.000 | 5.703e-11 | 25510 |

### EE – Ackley (n=10)

| modo sigma | recomb            | supervivencia | TE    | VAMM      | PEX   |
|------------|-------------------|---------------|-------|-----------|-------|
| 1          | discreta_global   | (mu,lambda)   | 1.000 | 2.673e-12 | 11390 |
| 1          | intermedia_global | (mu+lambda)   | 1.000 | 9.348e-13 | 10030 |
| n          | discreta_global   | (mu,lambda)   | 1.000 | 3.260e-12 | 16990 |
| n          | intermedia_global | (mu+lambda)   | 1.000 | 8.993e-13 | 25950 |

### Discusión de EE



Como criterio, priorizo primero TE por robustez. Si TE empata, comparo PEX. VAMM actúa como apoyo para ver si, además de llegar a  $\epsilon$ , la solución final es estable.

En Potencias todas las configuraciones alcanzan TE=1. La mejor (menor PEX) es: modo\_sigma=n, recomb=discreta\_global, supervivencia=(mu,lambda) con PEX=5630.0. Esto encaja con la intuición: al ser una función monomodal, la adaptación por componente (n sigmas) ayuda a ajustar la escala de cada dimensión y el esquema  $(\mu, \lambda)$  favorece la renovación evitando arrastrar padres cuando ya vamos bien encaminados.

En Ackley también se obtiene TE=1 en todas las combinaciones. La mejor por PEX es: modo\_sigma=1, recomb=intermedia\_global, supervivencia=(mu+lambda) con PEX=10030.0. En un paisaje multimodal como Ackley, mantener padres  $(\mu + \lambda)$  suele aportar estabilidad y evitar perder regiones prometedoras. La recombinación intermedia suaviza el movimiento y, combinada con  $\sigma$  global, tiende a controlar el salto para no “rebotar” entre mínimos locales.

### Curvas de progreso EE (mejor configuración)

Las siguientes curvas muestran el mejor fitness en escala logarítmica frente al número de evaluaciones. Se incluyen las 5 ejecuciones y una curva media en línea gruesa. (Además las dejo en una hoja en grande a parte para poder visualizarlo bien, lo cual repetiré más adelante para ED).



## Resultados para DE

Se evalúan 8 combinaciones: variante  $\in \{\text{rand, best}\}$ ,  $F \in \{0.5, 0.8\}$  y  $CR \in \{0.2, 0.9\}$ . El objetivo es ver cómo cambian exploración/explotación en cada función.

**DE – Potencias (n=10)**

| variante | F   | CR  | TE    | VAMM       | PEX  |
|----------|-----|-----|-------|------------|------|
| rand     | 0.5 | 0.2 | 1.000 | 0.000e+00  | 3408 |
| rand     | 0.5 | 0.9 | 1.000 | 4.676e-08  | 3480 |
| rand     | 0.8 | 0.2 | 1.000 | 3.327e-112 | 4932 |
| rand     | 0.8 | 0.9 | 1.000 | 6.055e-33  | 9066 |
| best     | 0.5 | 0.2 | 1.000 | 0.000e+00  | 1998 |
| best     | 0.5 | 0.9 | 1.000 | 1.121e-45  | 1284 |
| best     | 0.8 | 0.2 | 1.000 | 0.000e+00  | 3504 |
| best     | 0.8 | 0.9 | 0.800 | 4.500e+01  | 2430 |

**DE – Ackley (n=10)**

| variante | F   | CR  | TE    | VAMM      | PEX   |
|----------|-----|-----|-------|-----------|-------|
| rand     | 0.5 | 0.2 | 1.000 | 3.997e-15 | 10032 |
| rand     | 0.5 | 0.9 | 1.000 | 3.997e-15 | 8574  |
| rand     | 0.8 | 0.2 | 1.000 | 3.997e-15 | 15936 |
| rand     | 0.8 | 0.9 | 1.000 | 2.975e-08 | 30162 |
| best     | 0.5 | 0.2 | 1.000 | 6.128e-15 | 5778  |
| best     | 0.5 | 0.9 | 0.000 | 5.188e+00 | -     |
| best     | 0.8 | 0.2 | 1.000 | 3.997e-15 | 10554 |
| best     | 0.8 | 0.9 | 0.800 | 2.310e-01 | 7642  |

## Discusión de DE

En DE, además de TE/PEX, es importante observar cuándo ciertos parámetros degradan la robustez. Por ejemplo, una configuración puede ser rápida (PEX bajo) pero fallar en algunas ejecuciones ( $TE < 1$ ), lo cual la hace menos recomendable en un entorno real.



Por ejemplo, en Ackley se observa que una configuración agresiva como best,  $F=0.5$ ,  $CR=0.9$  puede dar buen PEX en algunas corridas, pero al tener  $TE < 1$  la descarto por falta de robustez; por eso elijo best,  $F=0.5$ ,  $CR=0.2$ , que mantiene  $TE=1$  y ofrece el menor PEX entre las configuraciones robustas.

En Potencias, varias configuraciones tienen  $TE=1$ . La más eficiente por PEX es: variante=best,  $F=0.5$ ,  $CR=0.9$  con  $PEX=1284.0$ . Potencias es monomodal, por lo que una estrategia 'best' suele acelerar. Además, un CR alto puede ayudar a incorporar más componentes del mutante y avanzar más rápido hacia el óptimo.

En Ackley, la mejor configuración con  $TE=1$  y menor PEX es: variante=best,  $F=0.5$ ,  $CR=0.2$  con  $PEX=5778.0$ . En multimodal, 'best' puede ser muy útil si no se vuelve demasiado agresivo. Aquí CR bajo (0.2) tiende a preservar parte del objetivo, evitando saltos excesivos que crucen el valle del mínimo global.

### Curvas de progreso DE (mejor configuración)

Las curvas de progreso de DE muestran normalmente una caída rápida al principio y después un tramo de estabilización cuando se alcanza  $\epsilon$ . En escala logarítmica se aprecia la velocidad con la que el algoritmo reduce el error.



## Comparación final EE vs DE

Para comparar de forma justa, uso el mismo criterio que en el primer ejercicio: primero verifico que ambos algoritmos sean eficaces (TE alto) y después comparo la eficiencia en coste (PEX).

### Potencias (monomodal)

En Potencias, tanto EE como DE alcanzan TE=1 en las mejores configuraciones. La diferencia aparece en PEX: DE llega al umbral con menos evaluaciones en promedio, por lo que es más eficiente en este caso.

| Algoritmo | TE    | VAMM      | PEX         |
|-----------|-------|-----------|-------------|
| <b>EE</b> | 1.000 | 5.088e-27 | <b>5630</b> |
| <b>DE</b> | 1.000 | 1.121e-45 | <b>1284</b> |

### Ackley (multimodal)

En Ackley el paisaje es más irregular. Aun así, con los parámetros evaluados, se obtienen configuraciones con TE=1 en ambos algoritmos. De nuevo, la comparación por PEX muestra que DE es más eficiente en número de evaluaciones.

| Algoritmo | TE    | VAMM      | PEX          |
|-----------|-------|-----------|--------------|
| <b>EE</b> | 1.000 | 9.348e-13 | <b>10030</b> |
| <b>DE</b> | 1.000 | 6.128e-15 | <b>5778</b>  |

### Ventajas e inconvenientes observados

- EE: la auto-adaptación de  $\sigma$  es un punto fuerte porque ajusta la escala de mutación durante la búsqueda.
- EE: el esquema  $(\mu+\lambda)$  puede aportar estabilidad en multimodal, pero aumenta el coste por generación si  $\lambda$  es grande.
- DE: suele converger con pocas evaluaciones y su implementación es muy directa (mutación diferencial + cruce + reemplazo).
- DE: ciertos parámetros (F, CR) pueden degradar TE; por tanto hay que justificarlos experimentalmente.
- En esta práctica, DE resultó más eficiente en PEX en ambas funciones, manteniendo TE alto con configuraciones adecuadas.

## Conclusiones Finales

- 1) Se han implementado EE y DE en continuo y se han evaluado con 5 ejecuciones por configuración en  $n=10$ .
- 2) En EE, la mejor combinación depende de la función: en Potencias destaca la adaptación por componente ( $\text{modo\_sigma}="n"$ ) y en Ackley la combinación con  $(\mu+\lambda)$  aporta estabilidad.
- 3) En DE, las variantes tipo 'best' con parámetros moderados ofrecieron la mejor eficiencia (PEX) cuando mantenían  $TE=1$ .
- 4) Comparando mejores configuraciones, DE fue más eficiente (menor PEX) tanto en Potencias como en Ackley, sin perder eficacia ( $TE \approx 1$ ).

Los resultados muestran que no existe una configuración universal: los operadores y parámetros se justifican en función del paisaje de búsqueda (monomodal vs multimodal) y mediante evaluación estadística, tal como ya se evidenció en la PEC1.

## Anexo: Reproducibilidad del código

Para reproducir los resultados:

- 1) Ejecutar `ee_de_evaluation.py` (código hijo de `ee_de_base.py`) para generar historiales y CSV de resumen.
- 2) Ejecutar `script_mejores_config.py` para seleccionar mejores configuraciones y generar las figuras incluidas en esta memoria ( $n=2$  y curvas).