

PEC 4

Algoritmos Evolutivos Paralelos de Grano Fino: análisis y discusión de mejoras en su diversidad respecto al tiempo de convergencia.

Autor: Jaime Ciriaco Beaumont

Asignatura: Computación Evolutiva - UNED

Resumen

Los algoritmos evolutivos paralelos de grano fino se organizan mediante una estructura espacial predeterminada manteniendo una geometría fija, de variadas formas, normalmente una malla o red, y cada individuo sólo interactúa con un conjunto reducido de vecinos (Manderick & Spiessens, 1989; Alba & Dorronsoro, 2008). En los algoritmos evolutivos clásicos, los individuos pueden competir y recombinarse entre todos, pero, en los de grano fino los métodos de evolución se aplican de forma local con las formas geométricas mencionadas con anterioridad. Este pequeño cambio, hace que las mejores soluciones se propaguen de forma más progresiva, que directamente en toda la población, imitando así más próximamente, el complejo modelo de evolución natural (Alba & Troya, 2000).

La idea principal de estos algoritmos no se encuentra simplemente en la paralelización de los mismos, sino en su capacidad de continuar la diversidad y reducir la convergencia prematura que puede ocurrir en los algoritmos de programación más convencionales (Carmona & Fernández-Galán, 2020; Alba & Dorronsoro, 2008). En esta PEC se revisan los fundamentos del algoritmo evolutivo paralelo de grano fino, su relación con los algoritmos genéticos celulares, sus principales topologías y vecindarios, y el efecto de la actualización síncrona y asíncrona sobre la presión selectiva.

En añadido, estudiaremos y analizaremos mejoras plausibles del algoritmo respaldadas por estudios científicos como podrían ser: los vecindarios adaptativos, las redes small-world, los modelos híbridos de grano fino y grano grueso y las aplicaciones multiobjetivo (Giacobini et al., 2005; Dorronsoro & Bouvry, 2011; Nebro et al., 2009). Finalmente, se realiza una crítica razonada de sus ventajas, limitaciones y posibles líneas futuras de investigación.

Palabras clave: algoritmos evolutivos, grano fino, algoritmos genéticos celulares, panmítico, diversidad, convergencia prematura, vecindarios adaptativos, paralelismo.

1. Introducción

Los algoritmos evolutivos son métodos de búsqueda y optimización inspirados en procesos naturales de evolución. Principalmente, trabajan con una población de soluciones candidatas que se transforma generación tras generación mediante selección, recombinación, mutación y reemplazo (Cantú-Paz, 2000; Carmona & Fernández-Galán, 2020). La selección favorece a los individuos de mayor calidad, mientras que los operadores de variación introducen cambios que permiten explorar nuevas regiones del espacio de búsqueda.

Uno de los problemas más comunes en este tipo de algoritmos es la convergencia prematura. Este fenómeno surge cuando la población pierde diversidad demasiado pronto y se concentra alrededor de una región concreta del espacio de búsqueda, que puede corresponder sólo a un pequeño grupo localizable (Carmona & Fernández-Galán, 2020). En ese caso, el algoritmo deja de explorar alternativas y sus posibilidades de encontrar soluciones mejores se reducen considerablemente al generalizar estos máximos locales.

Dentro de las técnicas aplicadas para mantener esta diversidad, se encuentran los algoritmos evolutivos paralelos de grano fino, que son el objetivo de análisis de esta PEC. En estos modelos, la población no se representa como un conjunto completamente mezclado de individuos, sino como una estructura espacial geométrica. Esto significa que cada individuo ocupa una posición en una malla bidimensional y solo puede interactuar con sus vecinos más cercanos (Manderick & Spiessens, 1989; Alba & Dorronsoro, 2008).

Esta forma de organizar la población cambia el concepto común de evolución. En un algoritmo evolutivo convencional, cualquier individuo puede competir o recombinarse con cualquier otro. En cambio, en un algoritmo de grano fino, las interacciones se restringen localmente. De esta forma, una solución de alta calidad no invade toda la población de forma inmediata, sino que se propaga gradualmente por la malla, sin afectar así a posibles variaciones de incluso mayor valor (Alba & Troya, 2000).

Los algoritmos evolutivos de grano fino también son denominados como algoritmos genéticos celulares, debido a su relación con los autómatas celulares. En ambos casos, el comportamiento global del sistema surge a partir de reglas locales aplicadas sobre una estructura espacial (Alba & Dorronsoro, 2008). En los algoritmos genéticos celulares, esas reglas locales corresponden a operadores evolutivos como selección, cruce, mutación y reemplazo.

El objetivo de este documento es revisar de forma crítica los algoritmos evolutivos paralelos de grano fino, fijándose tanto en sus fundamentos como en sus variantes más relevantes. En la sección 2 se presentan las bases del modelo de grano fino y su relación con el mantenimiento de la diversidad. En la sección 3 se analiza el funcionamiento del modelo base. En la sección 4 se revisan metodologías, mejoras del algoritmo en cuestión. En la sección 5 se realiza una discusión crítica de sus ventajas, limitaciones y posibles mejoras. Por último, la sección 6 recoge las conclusiones principales y posibles líneas de trabajo futuro.

2. Fundamentos de los algoritmos de grano fino

2.1. Diversidad y convergencia prematura

La diversidad de una población mide hasta qué punto sus individuos son diferentes entre sí. En la computación evolutiva, mantener diversidad es importante porque permite que el algoritmo explore varias regiones del espacio de búsqueda al mismo tiempo. Si todos los individuos son muy similares, el algoritmo queda reducido a pequeñas variaciones alrededor de una misma zona (Carmona & Fernández-Galán, 2020).

La convergencia prematura o estancamiento prematuro ocurre cuando esta pérdida de diversidad se produce demasiado pronto. En tal caso, la población puede quedar atrapada en un óptimo local y dejar de buscar soluciones mejores a las planteadas. Este problema empeora cuando la función de adaptación presenta muchos óptimos locales o zonas engañosas (Alba & Dorronsoro, 2008).

El mantenimiento de la diversidad puede aplicarse de distintas maneras, principalmente modificaciones aisladas o híbridas sobre cualquier factor que modifique el estado base del algoritmo evolutivo. Algunas técnicas modifican la función de adaptación, como el reparto de adaptación. Otras actúan sobre el emparejamiento de padres, como la restricción del emparejamiento. También existen técnicas que intervienen en la selección de supervivientes, como el agrupamiento. Los algoritmos de grano fino, en cambio, actúan principalmente sobre la estructura de la población (Carmona & Fernández-Galán, 2020).

Esta diferencia es importante. En lugar de penalizar individuos parecidos o modificar directamente el fitness, los algoritmos de grano fino limitan quién puede interactuar con quién. El resultado es una población espacialmente estructurada donde la información genética se propaga de forma progresiva aunque, por ende, de forma más lenta (Manderick & Spiessens, 1989).

2.2. Modelos paralelos en algoritmos evolutivos

Los algoritmos evolutivos paralelos pueden clasificarse en varios modelos. Los tres más habituales son el modelo “Master-Slave”, el modelo de grano grueso y el modelo de grano fino (Cantú-Paz, 2000; Harada & Alba, 2020).

En el modelo “Master-Slave”, existe una única población global. El paralelismo se utiliza principalmente para repartir el coste de evaluación de los individuos entre varios procesadores. Este modelo es útil cuando la función de evaluación es costosa, pero no cambia de forma significativa la dinámica evolutiva, ya que la población sigue siendo panmíctica (Cantú-Paz, 2000).

En los modelos de grano grueso, la población se divide en varias subpoblaciones o islas. Cada isla ejecuta su propio algoritmo evolutivo durante varias generaciones y, ocasionalmente, algunos individuos migran entre islas. Este modelo deja que distintas subpoblaciones exploren regiones diferentes del espacio de búsqueda (Cantú-Paz, 2000; Dorronsoro et al., 2011).

En los modelos de grano fino, la división es mucho más detallada o específica. Normalmente, cada individuo ocupa un nodo de una malla o red (las geometrías que comentamos al inicio), y solo interactúa con individuos cercanos de una forma predefinida. No hay subpoblaciones grandes claramente separadas, sino una única población estructurada de forma local (Manderick & Spiessens, 1989; Alba & Dorronsoro, 2008).

El grano fino, algoritmo principal en esta PEC, resulta especialmente interesante porque no solo permite paralelizar el algoritmo, sino que modifica el modo en que se propagan las soluciones. Por ello, su valor no es únicamente computacional, sino también evolutivo (Alba & Dorronsoro, 2008).

2.3. Concepto de grano fino

En un algoritmo evolutivo paralelo de grano fino, cada individuo de la población se coloca en una posición de una estructura predeterminada. Lo más habitual es utilizar una malla bidimensional, aunque también pueden utilizarse anillos, grafos regulares, grafos aleatorios o redes más complejas (Alba & Dorronsoro, 2008; Giacobini et al., 2005).

Cada individuo tiene asociado un vecindario. Este vecindario determina con qué individuos puede interactuar. La selección de padres, la recombinación y el reemplazo se realizan normalmente dentro de esa zona local (Manderick & Spiessens, 1989).

El esquema general de funcionamiento es el siguiente;

Se inicializa una población distribuida sobre una estructura espacial; Se evalúan todos los individuos; Para cada individuo se calcula su vecindad; Se seleccionan padres dentro de la vecindad; Se genera un descendiente mediante recombinación y mutación; Se evalúa el descendiente; Se decide si el descendiente reemplaza al individuo actual o a algún individuo cercano. El proceso continúa hasta cumplir la condición de parada.

La diferencia clave respecto a un algoritmo evolutivo clásico está en que la selección no se realiza sobre toda la población, sino sobre un entorno local. Por tanto, un individuo muy bueno solo influye inicialmente en sus vecinos. Si su información genética resulta útil, se irá extendiendo por la malla a lo largo de las generaciones (Alba & Troya, 2000).

Este mecanismo produce una difusión gradual de las soluciones. La población no converge como un bloque único, sino que diferentes regiones pueden evolucionar de forma parcialmente independiente. Esta es la base de su capacidad para mantener la diversidad (Alba & Dorronsoro, 2008).

2.4. Relación con algoritmos genéticos celulares

Los algoritmos evolutivos paralelos de grano fino están estrechamente relacionados con los algoritmos genéticos celulares. En estos algoritmos, los individuos se organizan como celdas de una malla y cada celda solo interactúa con sus vecinas (Alba & Dorronsoro, 2008).

La relación con los autómatas celulares resulta clara. En un autómata celular, cada celda actualiza su estado en función de reglas locales aplicadas sobre si y sus vecinos. En un algoritmo genético celular, cada individuo actualiza su estado mediante operadores evolutivos locales. En ambos casos, el comportamiento global surge de interacciones locales simples (Alba & Dorronsoro, 2008).

Esta idea ayuda a entender por qué los algoritmos de grano fino tienen una dinámica distinta a los modelos panmícticos. La población no evoluciona como una masa homogénea, sino como un conjunto de regiones conectadas. Algunas zonas pueden estar dominadas por una familia de soluciones, mientras otras siguen explorando alternativas (Manderick & Spiessens, 1989).

Alba y Dorronsoro (2008) aplican esta familia de algoritmos en su escrito sobre algoritmos genéticos celulares, donde se estudian topologías, vecindarios, modelos de actualización y aplicaciones. Esta obra es una referencia importante porque trata el grano fino no solo como una técnica de paralelización, sino como una forma específica de estructurar la búsqueda evolutiva.

2.5. Funcionamiento canónico del algoritmo de grano fino

El funcionamiento canónico de un algoritmo de grano fino puede entenderse como una repetición local del ciclo evolutivo. Para cada individuo de la población, se selecciona un conjunto de vecinos, se eligen padres dentro de ese conjunto, se aplica recombinación y mutación, y se decide si el nuevo individuo entra en la población (Carmona & Fernández-Galán, 2020; Alba & Dorronsoro, 2008).

La forma más sencilla de implementar consiste en recorrer todos los individuos de la población. Para cada uno, se calcula su vecindario. Después se seleccionan uno o varios padres, normalmente entre el individuo actual y sus vecinos. A partir de ellos se genera un descendiente. Finalmente, se compara el descendiente con el individuo actual o con algún miembro del vecindario y se decide el reemplazo.

Este esquema permite dos interpretaciones. Desde el punto de vista computacional, cada individuo o grupo de individuos podría procesarse de forma paralela. Desde el punto de vista evolutivo, la localidad regula la presión selectiva y evita que las mejores soluciones se extiendan demasiado rápido (Manderick & Spiessens, 1989; Alba & Troya, 2000).

3. Análisis del modelo de grano fino

3.1. Topologías de población

La topología define cómo están conectados los individuos entre sí. En los algoritmos de grano fino, la topología más habitual es la malla bidimensional. Esta estructura es fácil de visualizar, sencilla de implementar y se adapta bien a arquitecturas paralelas (Alba & Dorronsoro, 2008).

En una malla bidimensional, cada individuo ocupa una posición $((i,j))$. Sus vecinos se definen en función de su distancia dentro de la malla. Una decisión importante es cómo tratar los bordes. Si la malla es abierta, los individuos situados en los extremos tienen menos vecinos. Esto puede introducir diferencias artificiales entre individuos centrales y periféricos.

Para evitar este problema se suele utilizar una malla toroidal. En una malla toroidal, el borde superior se conecta con el inferior y el borde izquierdo con el derecho. Así, todos los individuos tienen el mismo número de vecinos, independientemente de su posición (Alba & Dorronsoro, 2008).

También se han propuesto otras topologías, como anillos, grafos regulares, redes aleatorias o redes small-world. Estas variantes permiten modificar la velocidad con la que se difunden las soluciones. Una red más conectada acelera la propagación de individuos buenos, pero reduce la diversidad. Una red menos conectada mantiene aislamiento local, pero puede ralentizar la convergencia (Giacobini et al., 2005).

3.2. Vecindarios de Von Neumann y Moore

Además de elegir la topología general, hay que definir el vecindario de cada individuo. En mallas bidimensionales, los vecindarios más comunes son el de Von Neumann y el de Moore (Alba & Dorronsoro, 2008).

El vecindario de Von Neumann incluye los cuatro vecinos ortogonales:

```

    x
x  O  x
    x

```

Es decir, norte, sur, este y oeste. Este vecindario mantiene baja la conectividad y favorece una difusión lenta de las soluciones. Por tanto, suele preservar mejor la diversidad (Alba & Dorronsoro, 2008).

En contra medida, el vecindario de Moore incluye los ocho vecinos alrededor del individuo:

```

x  x  x
x  O  x
x  x  x

```

Este vecindario permite mayor interacción. Al haber más vecinos, aumenta la presión selectiva y las buenas soluciones se expanden con más rapidez. Sin embargo, esta mayor conectividad también puede reducir diversidad más rápido.

La elección entre Von Neumann y Moore depende del problema. En los problemas más multimodales, puede ser preferible usar vecindarios algo pequeños para evitar convergencia prematura. En problemas más suaves o cuando interesa acelerar la convergencia, puede ser mejor usar vecindarios más mayores (Alba & Troya, 2000; Alba & Dorronsoro, 2005).

3.3. Ratio de vecindad

Alba y Troya (2000) estudiaron la influencia del ratio en los algoritmos evolutivos celulares. Este concepto mide la relación entre el tamaño de la vecindad y el tamaño total de la población. La idea es que no solo importa la forma del vecindario, sino también su tamaño relativo.

Un ratio pequeño implica interacción muy local. Esto favorece la exploración y diversidad, pero puede ralentizar la difusión de buenas soluciones. Un ratio grande implica una interacción más amplia. Esto favorece la explotación, pero puede acercar el comportamiento del algoritmo al de una población panmíctica (Alba & Troya, 2000).

El ratio permite formalizar el efecto de la vecindad sobre la búsqueda. En lugar de hablar únicamente de vecindarios pequeños o grandes, se puede analizar cuánto espacio de interacción tiene cada individuo respecto a la población completa (Alba & Dorronsoro, 2005).

3.4. Selección local y presión selectiva

En un algoritmo panmíctico, un individuo de alta calidad puede ser seleccionado muchas veces por toda la población. Esto acelera la convergencia, pero también puede hacer que la población pierda diversidad (Carmona & Fernández-Galán, 2020).

En un algoritmo de grano fino, la selección se aplica dentro del vecindario. Un individuo bueno solo influye inicialmente en los individuos cercanos. Esto reduce la presión selectiva global y permite que distintas regiones de la malla evolucionen de forma diferente (Manderick & Spiessens, 1989; Alba & Troya, 2000).

Este mecanismo puede entenderse como una forma de selección local. La presión selectiva sigue existiendo, pero queda distribuida espacialmente. Las regiones cercanas a buenos individuos tienden a mejorar, mientras otras zonas pueden seguir explorando alternativas.

En problemas multimodales, este comportamiento resulta especialmente útil. Distintas regiones de la población pueden explorar diferentes óptimos locales. Si una región encuentra una solución claramente superior, esta puede expandirse, pero no de forma instantánea (Alba & Dorronsoro, 2008).

3.5. Reemplazo local

El reemplazo también suele aplicarse de forma local. Después de generar un descendiente, el algoritmo decide si este entra en la población. Una regla simple consiste en reemplazar al individuo actual si el descendiente tiene mejor valor de adaptación (Alba & Dorronsoro, 2008).

Otra posibilidad es hacer competir al descendiente con el peor individuo del vecindario. También existen reglas probabilísticas, donde el descendiente puede reemplazar a otro individuo con una probabilidad dependiente de su calidad como selección de supervivencia.

La regla de reemplazo influye en la dinámica del algoritmo. Un reemplazo muy elitista acelera la mejora local, pero puede reducir la diversidad. Un reemplazo más permisivo mantiene más exploración, aunque puede ralentizar la convergencia (Alba & Dorronsoro, 2008).

3.6. Actualización síncrona y asíncrona

El modelo de actualización define la dinámica de reemplazo de la población. En la actualización síncrona, los descendientes se generan a partir de la población actual y la sustituyen en bloque al finalizar la generación (Alba & Dorronsoro, 2008). Por el contrario, la actualización asíncrona aplica los cambios de forma inmediata y secuencial, lo que puede acelerar la propagación de soluciones óptimas (Giacobini et al., 2003).

Esta elección influye directamente en la presión selectiva: el modelo asíncrono suele aumentarla, intensificando la explotación, mientras que el síncrono facilita un análisis más ordenado del equilibrio con la exploración (Giacobini et al., 2003). Así, la actualización no es solo un factor técnico de paralelización, sino un mecanismo evolutivo que regula la capacidad del algoritmo para evitar el estancamiento.

3.7. Exploración, explotación y difusión de soluciones

El equilibrio entre exploración (descubrimiento de nuevas regiones) y explotación (mejora de soluciones) es fundamental en computación evolutiva (Carmona & Fernández-Galán, 2020). En algoritmos de grano fino, este equilibrio se regula por la estructura de la población: vecindarios pequeños favorecen la exploración, limitando la difusión de soluciones, mientras que vecindarios amplios impulsan la explotación (Alba & Troya, 2000; Alba & Dorronsoro, 2005). La difusión de soluciones es progresiva, ya que las de alta calidad se extienden gradualmente por la malla, permitiendo a otras regiones continuar explorando (Manderick & Spiessens, 1989). La principal aportación del grano fino es que la presión selectiva se regula mediante la geometría de la población.

4. Metodologías, variantes y mejoras

4.1. Vecindarios adaptativos

Una de las mejoras más interesantes sobre el modelo clásico de grano fino es el uso de vecindarios adaptativos. En el modelo básico, el vecindario se define antes de ejecutar el algoritmo y permanece fijo durante toda la búsqueda. Sin embargo, esto puede ser demasiado rígido (Dorrnsoro & Bouvry, 2011).

En las primeras generaciones puede interesar mantener vecindarios pequeños, para favorecer la exploración y evitar que las soluciones iniciales dominen demasiado pronto. En fases posteriores, cuando ya se han localizado regiones prometedoras, puede ser conveniente ampliar el vecindario para acelerar la convergencia (Alba & Dorrnsoro, 2005).

Dorrnsoro y Bouvry (2011) proponen precisamente el uso de vecindarios adaptativos en algoritmos genéticos celulares. Esta línea resulta especialmente relevante porque actúa directamente sobre el elemento central del grano fino: la interacción local.

Desde un punto de vista práctico, adaptar el vecindario permite modificar la presión selectiva durante la ejecución. Si la población está perdiendo diversidad, el algoritmo puede reducir la conectividad. Si la población está demasiado dispersa y no mejora, puede aumentarla.

4.2. Topologías dinámicas y redes small-world

Otra línea de mejora consiste en abandonar la malla fija típica y utilizar topologías dinámicas o redes complejas. Las redes small-world, por ejemplo, combinan conexiones locales con algunas conexiones de largo alcance. Esto permite mantener cierta estructura local, pero facilita que la información se propague más rápido entre regiones alejadas (Giacobini et al., 2005).

El estudio del takeover time, o tiempo necesario para que una solución dominante se propague por la población, resulta útil para analizar este tipo de topologías. En una malla regular, la difusión puede ser lenta. En una red más conectada, la difusión se acelera (Giacobini et al., 2005).

Las topologías dinámicas permiten ajustar este comportamiento. Por ejemplo, una población podría empezar con una estructura muy local para preservar diversidad y, posteriormente, introducir conexiones adicionales para mejorar la explotación. También podrían añadirse conexiones entre regiones muy diferentes para favorecer el intercambio de información.

El riesgo de estas topologías es que pueden complicar el diseño y el análisis del algoritmo. Además, si se aumenta demasiado la conectividad, el modelo puede perder las ventajas propias del grano fino y acercarse a un modelo panmíctico.

4.3. Modelos híbridos de grano fino y grano grueso

Una extensión de las más interesantes consiste en combinar modelos de grano fino y grano grueso. En un modelo híbrido, se pueden crear varias islas, y dentro de cada isla utilizar una estructura celular (Dorronsoro et al., 2011).

Este enfoque combina dos niveles de diversidad. A escala global, las islas permiten explorar regiones diferentes del espacio de búsqueda. A escala local, la estructura celular dentro de cada isla evita que la subpoblación converja demasiado rápido.

Las migraciones entre islas permiten intercambiar información entre regiones alejadas, mientras que los vecindarios locales mantienen diversidad dentro de cada isla. Esta combinación puede ser especialmente útil en problemas complejos, donde interesa conservar diversidad tanto global como local (Dorronsoro et al., 2011).

El grano grueso suele ser más sencillo de aplicar en sistemas distribuidos, mientras que el grano fino ofrece un control más detallado de la presión selectiva. Por ello, los modelos híbridos son una línea prometedora, ya que intentan aprovechar las ventajas de ambos enfoques.

4.4. Algoritmos de grano fino en optimización multiobjetivo

Los algoritmos de grano fino también se han aplicado a problemas de optimización multiobjetivo. En estos problemas no se busca una única solución óptima, sino un conjunto de soluciones no dominadas que aproximan el frente de Pareto (Nebro et al., 2009).

En este contexto, mantener la diversidad es fundamental. No basta con encontrar una solución de alta calidad; es necesario obtener soluciones distribuidas a lo largo del frente. Por ello, los modelos celulares encajan de forma natural con la optimización multiobjetivo (Nebro et al., 2009).

Un ejemplo relevante es MOCeIl, un algoritmo genético celular para optimización multiobjetivo. Este algoritmo combina una estructura celular con un archivo externo de soluciones no dominadas. La interacción local ayuda a mantener la diversidad en la población, mientras que el archivo externo conserva las mejores soluciones encontradas (Nebro et al., 2009).

Esta aplicación muestra que el grano fino no solo sirve para optimización monobjetivo. También puede ser útil cuando la diversidad forma parte esencial del objetivo del algoritmo.

4.5. Control adaptativo basado en diversidad

Otra posibilidad consiste en usar medidas de diversidad para controlar el comportamiento del algoritmo. Si la diversidad cae por debajo de cierto umbral, el algoritmo podría reducir la conectividad, aumentar la mutación o introducir nuevas soluciones. Si la población mantiene

demasiada diversidad pero no mejora, podría aumentar la presión selectiva (Alba & Dorronsoro, 2005; Dorronsoro & Bouvry, 2011).

Este tipo de control permitiría ajustar dinámicamente el equilibrio entre exploración y explotación. En el caso concreto del grano fino, la variable más natural a adaptar sería el vecindario, ya que este controla la interacción local.

El control adaptativo basado en diversidad también podría combinarse con topologías dinámicas. Por ejemplo, regiones demasiado homogéneas podrían conectarse temporalmente con regiones más diversas. De este modo, se introduciría información nueva sin romper completamente la estructura espacial.

Esta línea resulta prometedora porque evita depender de una topología fija elegida manualmente antes de la ejecución. En su lugar, el algoritmo puede modificar su estructura en función del estado real de la búsqueda.

5. Discusión crítica

5.1. Ventajas principales

La principal ventaja de los algoritmos evolutivos paralelos de grano fino es su capacidad para mantener la diversidad de forma natural. Al limitar las interacciones al vecindario, se evita que un individuo muy bueno domine toda la población de forma inmediata (Manderick & Spiessens, 1989; Alba & Dorronsoro, 2008).

Otra ventaja es la exploración distribuida. Distintas zonas de la malla pueden evolucionar hacia soluciones diferentes. Esto resulta especialmente útil en problemas multimodales, donde es importante no abandonar demasiado pronto regiones alternativas.

También destaca su capacidad para regular la presión selectiva mediante la estructura. En lugar de modificar únicamente parámetros clásicos, como la probabilidad de mutación o el tamaño de torneo, el algoritmo puede controlar la búsqueda mediante la conectividad de la población (Alba & Troya, 2000; Alba & Dorronsoro, 2005).

Además, los algoritmos de grano fino son conceptualmente sencillos. La idea de organizar individuos en una malla y restringir las interacciones al vecindario es fácil de entender. Al mismo tiempo, esta idea sencilla produce una dinámica evolutiva rica y diferente a la de los modelos panmícticos.

Por último, su estructura local los hace adecuados para arquitecturas paralelas. Aunque la implementación real tenga dificultades, el modelo encaja bien con sistemas donde muchas unidades de procesamiento trabajan simultáneamente (Pinel et al., 2013; Harada & Alba, 2020).

5.2. Limitaciones principales

La primera limitación es la lentitud en la convergencia. Al propagarse localmente, las soluciones óptimas pueden tardar muchas generaciones en influir en toda la población, lo cual resulta ineficiente en problemas sencillos (Alba & Dorronsoro, 2008).

En segundo lugar, existe una fuerte dependencia de la topología y el vecindario. No hay una estructura universal ideal: vecindarios pequeños preservan la diversidad pero frenan la difusión, mientras que los grandes aceleran la convergencia a costa de reducir la diversidad prematuramente (Alba & Troya, 2000).

La tercera limitación reside en la implementación paralela. Pese a su naturaleza paralelizable, el hardware real introduce costes significativos en sincronización, comunicación y gestión de memoria (Pinel et al., 2013).

Cuarto, es difícil distinguir entre mejoras algorítmicas (calidad por diversidad) y computacionales (velocidad por paralelismo). Un algoritmo puede ser más rápido sin mejorar necesariamente la calidad de las soluciones (Harada & Alba, 2020).

Finalmente, su utilidad es específica del problema. Para escenarios simples, los modelos panmícticos suelen bastar; el grano fino solo es preferible ante riesgos de convergencia prematura o si se requiere mantener múltiples alternativas.

5.3. Comparación con modelos panmícticos

El modelo panmíctico es más simple. Todos los individuos forman una única población global y pueden interactuar libremente. Esta simplicidad puede ser ventajosa cuando el problema no presenta muchos óptimos locales y se busca una convergencia rápida (Cantú-Paz, 2000).

Sin embargo, la interacción global también puede ser un problema. Si aparece pronto una solución buena, puede extenderse rápidamente por toda la población. Esto puede llevar a una pérdida de diversidad y a una convergencia prematura (Carmona & Fernández-Galán, 2020).

El modelo de grano fino reduce ese riesgo al limitar la interacción. Las soluciones buenas se expanden poco a poco, lo que da más tiempo a otras regiones para explorar. Por tanto, el grano fino ofrece una búsqueda más conservadora y distribuida (Manderick & Spiessens, 1989; Alba & Dorronsoro, 2008).

En mi opinión, el modelo panmíctico es adecuado para problemas donde la explotación rápida es suficiente. En cambio, el grano fino resulta más conveniente cuando el problema es multimodal o cuando la diversidad es un factor crítico y necesario de abastecer.

5.4. Comparación con modelos de grano grueso

Los modelos de grano grueso dividen la población en varias islas. Cada isla evoluciona de forma relativamente independiente y, cada cierto tiempo, algunos individuos migran entre islas. Este enfoque permite mantener diversidad entre subpoblaciones y se adapta bien a sistemas distribuidos (Cantú-Paz, 2000).

El grano fino actúa a una escala más local. En lugar de dividir la población en islas grandes, organiza a los individuos en una malla donde cada uno interactúa con sus vecinos. Esto produce una difusión más continua y gradual aunque más tardía (Alba & Dorronsoro, 2008).

Ambos modelos tienen ventajas. El grano grueso es más fácil de escalar en clústeres o sistemas distribuidos. El grano fino permite controlar con mayor detalle la presión selectiva local. Por ello, no deberían considerarse enfoques excluyentes.

Los modelos híbridos resultan especialmente interesantes. Una arquitectura con varias islas celulares permitiría mantener diversidad global mediante migraciones y diversidad local mediante vecindarios. Esta combinación puede ser útil en problemas de gran tamaño o con paisajes de búsqueda muy complejos (Dorronsoro et al., 2011).

5.5. Valoración personal

Desde mi punto de vista, el valor principal de los algoritmos evolutivos paralelos de grano fino no está solo en la paralelización, sino en su aportación más interesante al modificar la dinámica evolutiva mediante interacción local.

La población deja de comportarse como una masa homogénea y pasa a comportarse como una red de regiones que evolucionan de forma parcialmente independiente. Esto ayuda a preservar la diversidad y evita que una solución aparentemente buena domine demasiado pronto (Alba & Dorronsoro, 2008).

El valor principal del grano fino es su capacidad estructural para controlar el equilibrio entre exploración y explotación mediante la interacción local, ayudando a preservar la diversidad (Alba & Dorronsoro, 2008). No obstante, una interacción demasiado restrictiva puede ralentizar la difusión de buenas soluciones. Por ello, considero que los vecindarios adaptativos son la mejora más natural, ya que un vecindario fijo no responde a la necesidad cambiante de favorecer la exploración (inicial) y la explotación (final) (Dorronsoro & Bouvry, 2011).

En este marco de soluciones dinámicas, lo ideal sería además añadir la hibridación entre modelos de grano fino y grano grueso siendo esta dentro de lo investigado la opción ideal (Híbrido grano grueso + grano fino + vecindarios adaptativos). En este esquema, la población se dividiría en varias islas, como en los modelos de grano grueso, pero cada isla estaría organizada internamente como una población celular. Además, el vecindario dentro de cada isla podría modificarse dinámicamente durante la ejecución. De esta forma, las islas aportarían diversidad global, la estructura celular mantendría diversidad local, y la adaptación del vecindario permitiría ajustar la presión selectiva según el estado de la búsqueda.

5.6. Líneas de mejora más prometedoras

La primera línea de mejora es el uso de vecindarios adaptativos. Esta idea permite comenzar con interacción local reducida y aumentar la conectividad cuando sea necesario acelerar la convergencia. También podría hacerse al revés si se detecta pérdida de diversidad (Dorrnsoro & Bouvry, 2011).

La segunda línea es el uso de topologías dinámicas. En lugar de mantener fija la malla, el algoritmo podría modificar conexiones durante la ejecución. Esto permitiría combinar estabilidad local con comunicación global ocasional (Giacobini et al., 2005).

La tercera línea es la hibridación entre grano fino y grano grueso en mi opinión la más interesante si se controlan correctamente los hiperparámetros. Este enfoque permitiría trabajar con varias islas, cada una de ellas organizada internamente como una población celular. Así se combinaría diversidad global y diversidad local (Dorrnsoro et al., 2011).

La cuarta línea es la integración con optimización multiobjetivo. Dado que en los problemas multiobjetivo es necesario mantener diversidad a lo largo de un frente de Pareto, los modelos celulares ofrecen una estructura adecuada para distribuir soluciones (Nebro et al., 2009).

6. Conclusiones y trabajo futuro

Los algoritmos evolutivos paralelos de grano fino son una técnica importante dentro del mantenimiento de la diversidad en computación evolutiva. El modelo resulta especialmente útil en problemas multimodales, donde existe riesgo de convergencia prematura hacia óptimos locales. También es interesante en problemas multiobjetivo, donde la diversidad de soluciones es parte esencial del objetivo (Nebro et al., 2009).

No obstante, el grano fino no es una solución universal. Su rendimiento depende mucho de factores e hiperparámetros. Un diseño demasiado localizado puede ralentizar la convergencia y uno demasiado conectado puede eliminar las ventajas de diversidad (Alba & Troya, 2000; Alba & Dorrnsoro, 2005).

La principal conclusión es que el grano fino debe entenderse como una forma estructural de controlar el equilibrio entre exploración y explotación.

Como trabajo futuro, la línea más interesante son los vecindarios adaptativos junto con la hibridación de grano fino y grano grueso. Esta combinación permitiría integrar tres mecanismos complementarios: aislamiento entre subpoblaciones, interacción local entre individuos y control dinámico de la conectividad.

Referencias bibliográficas

Alba, E., & Dorronsoro, B. (2005). *The Exploration/Exploitation Tradeoff in Dynamic Cellular Genetic Algorithms*. IEEE Transactions on Evolutionary Computation, 9(2), 126–142. <https://doi.org/10.1109/TEVC.2005.843751>

Alba, E., & Dorronsoro, B. (2008). *Cellular Genetic Algorithms*. Springer. <https://doi.org/10.1007/978-0-387-77610-1>

Alba, E., & Troya, J. M. (2000). *Cellular Evolutionary Algorithms: Evaluating the Influence of Ratio*. En M. Schoenauer et al. (Eds.), *Parallel Problem Solving from Nature - PPSN VI*, Lecture Notes in Computer Science, 1917, 29–38. Springer. https://doi.org/10.1007/3-540-45356-3_3

Cantú-Paz, E. (2000). *Efficient and Accurate Parallel Genetic Algorithms*. Springer.

Carmona, E. J., & Fernández-Galán, S. (2020). *Fundamentos de la Computación Evolutiva*. Marcombo.

Dorronsoro, B., & Bouvry, P. (2011). *Adaptive Neighborhoods for Cellular Genetic Algorithms*. Nature Inspired Distributed Computing sessions of the International Parallel and Distributed Processing Symposium Workshops, 383–389. <https://doi.org/10.1109/IPDPS.2011.168>

Dorronsoro, B., Danoy, G., Bouvry, P., & Alba, E. (2011). *Evaluation of a Cooperative Hybrid Parallel Evolutionary Algorithm*. IEEE International Parallel & Distributed Processing Symposium, 1285–1292. <https://doi.org/10.1109/IPDPS.2011.272>

Giacobini, M., Alba, E., & Tomassini, M. (2003). *Selection Intensity in Asynchronous Cellular Evolutionary Algorithms*. Genetic and Evolutionary Computation Conference, Lecture Notes in Computer Science, 2723, 955–966. Springer. https://doi.org/10.1007/3-540-45105-6_107

Giacobini, M., Tomassini, M., & Tettamanzi, A. (2005). *Takeover Time Curves in Random and Small-World Structured Populations*. Proceedings of the Genetic and Evolutionary Computation Conference, 1333–1340.

Harada, T., & Alba, E. (2020). *Parallel Genetic Algorithms: A Useful Survey*. ACM Computing Surveys, 53(4). <https://doi.org/10.1145/3400031>

Manderick, B., & Spiessens, P. (1989). *Fine-Grained Parallel Genetic Algorithms*. Proceedings of the Third International Conference on Genetic Algorithms, 428–433.

Nebro, A. J., Durillo, J. J., Luna, F., Dorronsoro, B., & Alba, E. (2009). *MOCeL: A Cellular Genetic Algorithm for Multiobjective Optimization*. International Journal of Intelligent Systems, 24(7), 726–746. <https://doi.org/10.1002/int.20358>

Pinel, F., Dorronsoro, B., Bouvry, P., & Khan, S. U. (2013). *A Cellular Genetic Algorithm for the GPU*. Computer Communications, 36(15–16), 1633–1641. <https://doi.org/10.1016/j.comcom.2013.07.001>