

Ejercicios PEC 1 M.P.

Fundamentos de redes bayesianas

por Jaime Ciriaco Beaumont

Yo, Jaime Ciriaco Beaumont, prometo por mi honor que he realizado estos ejercicios personalmente, sin consultar las respuestas de otros estudiantes y sin utilizar herramientas de IA generativa.

Ejercicio 1.1.

Distribución de probabilidades:

a	b	c	$P(a, b, c)$
$+a$	$+b$	$+c$	0,12
$+a$	$+b$	$\neg c$	0,03
$+a$	$\neg b$	$+c$	0,48
$+a$	$\neg b$	$\neg c$	0,12
$\neg a$	$+b$	$+c$	0,02
$\neg a$	$+b$	$\neg c$	0,08
$\neg a$	$\neg b$	$+c$	0,03
$\neg a$	$\neg b$	$\neg c$	0,12

Empezaré calculando las variables presentes y ausentes marginales lo cual me ahorrará tiempo en el cálculo consiguiente de las independencias sugeridas por el ejercicio:

$$P(+a) = 0.12 + 0.03 + 0.48 + 0.12 = 0.75 \quad /// \quad P(-a) = 0.02 + 0.08 + 0.03 + 0.12 = 0.25$$

$$P(+b) = 0.12 + 0.03 + 0.02 + 0.08 = 0.25 \quad /// \quad P(-b) = 0.48 + 0.12 + 0.03 + 0.12 = 0.75$$

$$P(+c) = 0.12 + 0.48 + 0.02 + 0.03 = 0.65 \quad /// \quad P(-c) = 0.03 + 0.12 + 0.08 + 0.12 = 0.35$$

Vamos a indicar para la primera y la última relación de independencia, expresadas en el enunciado, los pasos que se han tomado y para el resto simplemente indicaremos si la expresión es verdadera o falsa:

1. $IP(A,B) = \text{FALSA}$

Fórmula de independencia aplicada al caso : $P(a,b) = P(a) * P(b)$

$P(a,b)$ es la posibilidad de que a y b existan a la vez, volviendo a la tabla vemos que esto ocurre solo en las 2 primeras filas, por lo que $P(a,b) = 0.12 + 0.03 = 0.15$

Ahora tenemos que comprobar si la probabilidad marginal de a y la de b multiplicadas nos da el mismo valor que la probabilidad de que aparezcan juntas. Volviendo a los cálculos que hice con anterioridad $P(a) = 0.75$ y $P(b) = 0.25$ que al multiplicarlas da aproximadamente $0.19 \neq 0.15$ por lo tanto no cumple la condición para que sea correcta la afirmación, por lo tanto $IP(A,B)$ es falso.

2. $IP(A,C) = \text{FALSA}$

3. $IP(B,C) = \text{FALSA}$

4. $IP(B,C | A) = \text{VERDADERA}$

5. $IP(A,C | B) = \text{FALSA}$

6. $IP(A,B | C) = \text{FALSA}$

Fórmula de independencia aplicada al caso : $P(a,b | c) = P(a | c) * P(b | c)$

$P(a,b | c)$ es la posibilidad de que a y b existan a la vez dado que c exista, volviendo a la tabla vemos que esto ocurre solo en la primera fila, por lo que $P(a,b | c) = 0.12$

Ahora tenemos que comprobar si la probabilidad marginal de a dado que c exista y la de b dado que c exista multiplicadas nos da el mismo valor que la probabilidad de que aparezcan juntas dado que c exista. Para aplicar la probabilidad condicional en las marginales de a y b simplemente cogeremos los valores de cada una cuando existan dado que c exista.

$P(a | c) = 0.12 + 0.48 = 0.60$ y $P(b | c) = 0.12 + 0.02 = 0.14$ que al multiplicarlas da $0.084 \neq 0.12$ por lo tanto no cumple la condición para que sea correcta la afirmación, por lo tanto $IP(A,B | C)$ es falso.


Extra: sé que la fórmula de probabilidad condicional pide dividir por la probabilidad de la variable que condiciona " $P(c)$ " pero al tener la misma división a los 2 lados de la ecuación vi que se podía evitar dividir por 0.65 a todo manteniendo la proporción.

Ejercicio 1.2.


Desarrollar grafos a partir de problemas médicos:

Los siguientes grafos han sido desarrollados en OpenMarkov en base a las indicaciones de cada enunciado dentro del ejercicio 1.1


1




2




3





Ejercicio 1.3.

Vamos a analizar el enunciado para pasar las cosas que conocemos en concepto de fórmulas y grafos. El siguiente grafo que describe el enunciado del ejercicio:



Vamos a analizar los nodos de ascendente a descendente para seguir un orden.

De T sabemos que la posibilidad de padecerlo en la infancia es del 5% por lo que podemos decir que $P(+t) = 0.05$ y $P(-t) = 0.95$.

Ahora tenemos A que va condicionada por su padre T, y los datos que sabemos es que A se presenta el 70% de las veces cuando hay T y cuando no hay T solo un 1%. En base a lo anterior resumimos poniendo en expresión que $P(+a | +t) = 0.7$ y $P(+a | -t) = 0.01$. En consecuencia la probabilidad de que no aparezca A respecto de T será inversamente proporcional a los valores mostrados con anterioridad siendo $P(-a | +t) = 0.3$ y $P(-a | -t) = 0.99$.

Hecho en tabla:

T	$P(+a T)$	$P(-a T)$
+t	0.7	0.3
-t	0.01	0.99

Antes de entrar con el síntoma S vamos a trabajar la enfermedad B, pues de él sabemos que “prevalece” como dice en el enunciado, osea se, está presente el 3% por lo que $P(+b) = 0.03$ y $P(-b) = 0.97$.

También sabemos gracias a la prueba L de laboratorio que la sensibilidad, que sería la probabilidad de que exista L dado que exista B, vale 80% y que la especificidad que sería la probabilidad de que no exista L dado que no exista B, vale 94% siendo esto en forma de fórmula $P(+l | +b) = 0.8$ y $P(-l | -b) = 0.94$. Y la misma lógica de los inversos que hicimos con A y T.

Hecho en tabla:

B	$P(+l B)$	$P(-l B)$
+b	0.8	0.2
-b	0.06	0.94

Ahora sí, vamos con la probabilidad de S con respecto de A y B. Del enunciado sabemos que solo la enfermedad A produce en el 80% de los casos el síntoma S y la enfermedad B lo produce un 90% de las veces. Además, nos indican que las personas que no presentan ni A ni B, solo producen el síntoma el 1% de las veces.

Voy a indicar respectivamente en forma de fórmula lo expresado en el párrafo anterior:

$$P(+s \mid +a, -b) = 0.8 \quad \text{////} \quad P(+s \mid -a, +b) = 0.9 \quad \text{////} \quad P(+s \mid -a, -b) = 0.01$$

Para hacer la tablatura aún nos queda un caso pues a la hora de maniobrar con 2 variables binarias tenemos que tener 4 casos posibles y con lo expresado solo tenemos 3. El caso que nos queda es cuando la enfermedad A y B coexisten.
 $P(+s \mid +a, +b) = ??$

En esta ocasión aplicaremos la hipótesis causal del modelo OR probabilista, la cual explica que cada causa por sí sola es suficiente para producir el efecto y cuando hay varias causas no interactúan entre sí. Aplicado a nuestro caso sería como, A puede causar S el 80% y B puede causar S el 90%. Si hay un individuo que tiene A y B, no asumimos interacción entre A y B, simplemente seguirán las mismas probabilidades existiendo en un mismo cuerpo, pero si se hace menos probable que ninguna de las 2 produzca el síntoma.

Usando la expresión de noisy-OR en el ejercicio quedaría así:

$$P(+s \mid +a, +b) = 1 - (1 - P(+s \mid -a, -b)) * (1 - P(+s \mid +a, -b)) * (1 - P(+s \mid -a, +b))$$

$$P(+s \mid +a, +b) = 1 - (1 - 0.01) * (1 - 0.8) * (1 - 0.9) = 0.98$$


La hipótesis aplicada parece ser una buena aproximación puesto que aunque A y B ya son porcentajes muy elevados, no tenemos un 100% o más, simplemente ha aumentado la probabilidad al estar presentes las 2 variantes causales.

Hecho en tabla:

A	B	$P(+s \mid A, B)$	$P(-s \mid A, B)$
+a	+b	0.98	0.02
-a	+b	0.9	0.1
+a	-b	0.8	0.2
-a	-b	0.01	0.99

Tabla de combinaciones de hallazgos:

Indicar que, todo ha sido calculado mediante el grafo en OpenMarkov habiendo aplicado las probabilidades extraídas. La siguiente imagen presenta un ejemplo del grafo ya programado en modo inferencia mostrando el primer caso de la tabla:



T	S	L	Diagnóstico (La más alta entre A o B)
+	+	+	A
+	+	-	A
+	+	?	A
+	-	+	A
+	-	-	A
+	-	?	A
+	?	+	A
+	?	-	A

+	?	?	A
-	+	+	B
-	+	-	A
-	+	?	B
-	-	+	B
-	-	-	A
-	-	?	B
-	?	+	B
-	?	-	A
-	?	?	B
?	+	+	B
?	+	-	A
?	+	?	A
?	-	+	B
?	-	-	A
?	-	?	A
?	?	+	B
?	?	-	A
?	?	?	A

Para hacer la demostración de que, además de con Markov, se hacer el cálculo a mano, he planteado los siguientes casos:

Caso 1: T, S, L = Presentes /// Caso 2: T, S, L = Ausentes

Caso 1

Planteamos la probabilidad de A y B dado que T, S y L existan:

$$P(a,b \mid t,s,l) = P(a,b,t,s,l) / P(t,s,l)$$

Pero como el denominador no depende de las variables que intentamos diagnosticar podemos despejar como hice en el ejercicio 1.1 indicando que:

$P(a,b \mid t,s,l)' = P(a,b,t,s,l)$ Por eso indico que es la versión prima, pues es una versión donde estamos ignorando el efecto de la constante de normalización.

Ahora aplicamos que en una red bayesiana, la probabilidad conjunta de todas las variables es el producto de cada variable condicionada a sus padres en el grafo, por esto indicamos que $P(a,b,t,s,l) = P(t) * P(a \mid t) * P(b) * P(s \mid a,b) * P(l \mid b)$

Igualando ecuaciones nos quedaría que:

$$P(a,b \mid t,s,l)' = P(t) * P(a \mid t) * P(b) * P(s \mid a,b) * P(l \mid b)$$

Lo siguiente sería recordar estas probabilidades simplificadas para los casos donde existen las variables causales sustituyendo por los valores del enunciado:

$$P(+t) = 0.05$$

$$P(+a \mid +t) = 0.70, P(-a \mid +t) = 0.30$$

$$P(+b) = 0.03, P(-b) = 0.97$$

$$P(+l \mid +b) = 0.80, P(+l \mid -b) = 0.06$$

$$P(+s \mid A,B): (+a,+b) = 0.98 \quad (+a,-b) = 0.80 \quad (-a,+b) = 0.90 \quad (-a,-b) = 0.01$$

Ya tenemos la fórmula simplificada de la expresión de dependencia compleja y los valores a rellenar por lo que vamos a hacer la fórmula con todas las combinaciones de A y B. Vamos a desarrollar los numeradores de cada caso:

$$\text{Caso } (+a, +b) : N_{++} = 0.05 * 0.70 * 0.03 * 0.9802 * 0.80 = 0.000823368$$

$$\text{Caso } (+a, -b) : N_{+-} = 0.05 * 0.70 * 0.97 * 0.80 * 0.06 = 0.0016296$$

$$\text{Caso } (-a, +b) : N_{-+} = 0.05 * 0.30 * 0.03 * 0.90 * 0.80 = 0.000324$$

$$\text{Caso } (-a, -b) : N_{--} = 0.05 * 0.30 * 0.97 * 0.01 * 0.06 = 0.00000873$$

Ahora para obtener la constante de normalización sumamos todos los casos donde $Z = N_{++} + N_{+-} + N_{-+} + N_{--} = 0.000823368 + 0.0016296 + 0.000324 + 0.00000873 = 0.002785698$

Finalmente buscamos el caso de probabilidad de cada diagnóstico ahora que conocemos todos los valores de las ecuaciones donde nos fijamos en el mayor valor el cual indicará mayor probabilidad. La ecuación suma los casos donde existe la enfermedad a diagnosticar

$$P(a \mid t,s,l) = (N_{++} + N_{+-}) / Z = (0.000823368 + 0.0016296) / 0.002785698 = 0.88$$

$$P(b \mid t,s,l) = (N_{++} + N_{-+}) / Z = (0.000823368 + 0.000324) / 0.002785698 = 0.41$$

Diagnóstico final: A, porque $0.88 > 0.41$

Caso 2

Planteamos la probabilidad de A y B dado que T, S y L no existan y haciendo el mismo desarrollo que en ejercicio anterior llegamos a que:

$$P(a,b \mid t,s,l)' = P(t) * P(a \mid t) * P(b) * P(s \mid a,b) * P(l \mid b)$$

Probabilidades simplificadas para los casos donde no existen las variables causales:

$$P(-t) = 0.95 \quad P(+a \mid -t) = 0.01, \quad P(-a \mid -t) = 0.99 \quad P(+b) = 0.03, \quad P(-b) = 0.97$$

$$P(-l \mid +b) = 0.20, \quad P(-l \mid -b) = 0.94$$

$$P(-s \mid A,B): (+a,+b) = 0.02 \quad (+a,-b) = 0.2 \quad (-a,+b) = 0.1 \quad (-a,-b) = 0.99$$

Siguiendo los pasos del anterior caso, vamos a desarrollar los numeradores:

$$\text{Caso } (+a, +b) : N_{++} = 0.95 * 0.01 * 0.03 * 0.02 * 0.20 = 0.00000114$$

$$\text{Caso } (+a, -b) : N_{+-} = 0.95 * 0.01 * 0.97 * 0.20 * 0.94 = 0.00173242$$

$$\text{Caso } (-a, +b) : N_{-+} = 0.95 * 0.99 * 0.03 * 0.10 * 0.20 = 0.0005643$$

$$\text{Caso } (-a, -b) : N_{--} = 0.95 * 0.99 * 0.97 * 0.99 * 0.94 = 0.848972421$$

Ahora para obtener la constante de normalización sumamos todos los casos donde

$$Z = N_{++} + N_{+-} + N_{-+} + N_{--} = 0.00000114 + 0.00173242 + 0.0005643 + 0.848972421 = 0.851270281$$

Y buscamos el caso más probable:

$$P(a \mid -t,-s,-l) = (N_{++} + N_{+-}) / Z = (0.00000114 + 0.00173242) / 0.851270281 = 0.002$$

$$P(b \mid -t,-s,-l) = (N_{++} + N_{-+}) / Z = (0.00000114 + 0.0005643) / 0.851270281 = 0.00066$$

Diagnóstico final: A, porque $0.002 > 0.00066$

Ejercicio 1.4.

Vamos a plantear teóricamente el ejercicio 1.3 con la metodología del bayesiano ingenuo donde se afirma que si conozco la enfermedad, entre A y B en este caso, entonces los hallazgos, entre T, S y L en este caso, son independientes entre sí. Además, en el ejercicio iremos comparando los pasos entre redes bayesianas y bayesiano ingenuo.

Caso 1:

Planteamos la probabilidad de A y B dado que T, S y L existan:

$$P(a | t,s,l) \text{ y } P(b | t,s,l)$$

Aplicando el teorema de Bayes tenemos:

$$P(a | t,s,l) = P(t,s,l | a) * P(a) / P(t,s,l)$$

$$P(b | t,s,l) = P(t,s,l | b) * P(b) / P(t,s,l)$$

De nuevo, como el denominador $P(t,s,l)$ es el mismo en ambos casos y no depende del diagnóstico, lo ignoramos como hicimos en el ejercicio 1.1, trabajando con versiones proporcionales:

$$P(a | t,s,l)' = P(t,s,l | a) * P(a)$$

$$P(b | t,s,l)' = P(t,s,l | b) * P(b)$$

Ahora aplicamos la hipótesis del bayesiano ingenuo: dados A o B, los hallazgos T, S y L son independientes entre sí. Por tanto:

$$P(t,s,l | a) = P(t | a) * P(s | a) * P(l | a)$$

$$P(t,s,l | b) = P(t | b) * P(s | b) * P(l | b)$$

Sustituimos en las expresiones anteriores:

$$P(a | t,s,l)' = P(a) * P(t | a) * P(s | a) * P(l | a)$$

$$P(b | t,s,l)' = P(b) * P(t | b) * P(s | b) * P(l | b)$$

Usando los valores del enunciado:

$P(a)$ = probabilidad previa de A

$P(b)$ = probabilidad previa de B

$P(t | a)$, $P(s | a)$, $P(l | a)$ se obtienen directamente del modelo ingenuo, asumiendo que cada hallazgo depende solo de la enfermedad.

Calculando ambos valores y comparándolos, el diagnóstico será la enfermedad que presente mayor probabilidad.

Caso 2:

Repetimos exactamente el mismo procedimiento, pero ahora considerando los valores negativos de los hallazgos:

$$P(a | -t, -s, -l)' = P(a) * P(-t | a) * P(-s | a) * P(-l | a)$$

$$P(b | -t, -s, -l)' = P(b) * P(-t | b) * P(-s | b) * P(-l | b)$$

Sustituimos los valores correspondientes a los casos negativos y calculamos ambas probabilidades.

El diagnóstico final será, de nuevo, la enfermedad que presente mayor probabilidad posterior.

Comparación con la red bayesiana del ejercicio 1.3

La diferencia fundamental entre ambos enfoques es que:

- En la red bayesiana se modelan explícitamente las relaciones causales entre las variables
- En el bayesiano ingenuo se ignoran estas relaciones y se asume independencia entre los hallazgos dado el diagnóstico.

Por esto, el bayesiano ingenuo es demasiado simple en comparación a la red bayesiana ya que no tiene en cuenta las dependencias causales.

Todo esto pasado al papel sería que la red bayesiana plantea las posibilidades de A y B existan dadas las variables causales L, S y T, y el bayesiano ingenuo plantea lo inverso, plantea los hallazgos de L, S y T existan dadas las variables causales A y B