

Aplicaciones de los modelos gráficos probabilistas

Alumno: Jaime Ciriaco Beaumont

Asignatura: Métodos probabilistas - UNED

Curso: 2025/2026

Yo, Jaime Ciriaco Beaumont, prometo por mi honor que he realizado estos ejercicios personalmente, sin consultar las respuestas de otros estudiantes y sin utilizar herramientas de IA generativa.

1. Delimitación y motivación del tema

En el siguiente documento analizaremos el uso de modelos gráficos probabilistas, MGPs, para representar interacciones estratégicas entre agentes inteligentes. El punto no es la inteligencia artificial específicamente, sino, en un subcampo más concreto: modelos capaces de describir cómo varios agentes humanos, sistemas artificiales o ambos toman decisiones bajo incertidumbre, anticipan acciones ajenas y, en algunos casos, razonan sobre las creencias de otros agentes.

La elección del tema responde a mi interés personal por la interacción entre varias IAs y por el tipo de razonamiento que aparece cuando distintos agentes deben cooperar o, competir o evaluarse entre sí. Como profesor de IA y Big Data, me interesa especialmente esta zona intermedia entre la parte técnica y la parte filosófica de la inteligencia artificial. Cuando hablamos realmente de inteligencia, qué significa razonar sobre otros agentes y cómo se distingue una conducta inteligente de una simple cadena de instrucciones.

Los modelos gráficos probabilistas son de lo más adecuados para estudiar estas cuestiones porque obligan a hacer explícitos los elementos relevantes del problema: incertidumbre, decisiones, información disponible, utilidades, dependencias entre variables y creencias de los agentes. Por esto, el trabajo se centra en diagramas de influencia multiagente, redes de diagramas de influencia, juegos gráficos, teoría de juegos epistémica y extensiones recientes hacia teoría de la mente en agentes IA.

2. Alcance de la bibliografía disponible

Para tener en cuenta el volumen aproximado de referencias disponibles realizamos varias búsquedas en Google con términos específicos del campo. Los resultados obtenidos muestran que los conceptos relacionados con juegos gráficos, diagramas de influencia, teoría de la mente y agentes de IA aparecen en numerosos y variados contextos.

Búsqueda	Resultados aproximados
"multi-agent influence diagrams"	Aprox. 92.300.000 resultados
"networks of influence diagrams"	Aprox.345.000.000 resultados
"graphical games" "Nash equilibrium"	Aprox. 1.840.000 resultados
"theory of mind" "causal model"	Aprox. 55.600.000 resultados
"epistemic game theory" "AI agents"	Aprox. 6.100.000 resultados

Tabla 1. Resultados aproximados de los textos planteados de búsqueda para analizar la bibliografía disponible en base al buscador de Google en el apartado de herramientas.

Estas cifras no deben entenderse como el número exacto de trabajos académicos directamente relevantes, sino como una indicación de que el área general es amplia y mucho más actualmente con la burbuja y el amarillismo de la IA. Al restringir el análisis a trabajos que combinen explícitamente modelos gráficos probabilistas con interacción estratégica entre agentes, el conjunto se vuelve bastante más viable.

Por tanto, el campo general es extenso, pero el núcleo seleccionado para este análisis está suficientemente acotado: MAIDs, NIDs, juegos gráficos, LIMIDs y modelos de teoría de la mente en IA. Esta delimitación permite comparar varias referencias relevantes sin ser un tema demasiado general, como “modelos gráficos en inteligencia artificial” o “redes bayesianas en IA” como se comentaba en el enunciado.

3. Dificultades del área y fuentes de incertidumbre

Esta área presenta dificultades propias frente a otras aplicaciones de MGPs. La incertidumbre no procede solo del entorno, como puede ocurrir en el diagnóstico médico, predicción o sensores, sino que también viene de otros condicionantes como: sus objetivos, su información, sus estrategias, sus errores o incluso posibles intentos de engaño.

Además, las variables de decisión tienen un papel principal. No se trata solo de saber qué está pasando, sino de elegir qué hacer y prever cómo puede afectar esa acción a otros agentes. Por eso los diagramas de influencia y sus variantes multi-agente encajan bien. Estos permiten representar en un mismo modelo el azar, las decisiones y las consecuencias de esas decisiones.

También hay un nivel extra de complejidad, los agentes pueden tener creencias sobre otros agentes. Por ejemplo, una IA puede intentar anticipar qué cree otra IA, o incluso qué cree esa otra IA sobre ella y así hasta lo que el hardware les dé. Este tipo de razonamiento epistémico conecta con la teoría de la mente, porque no solo se analizan acciones, sino también intenciones, información y expectativas.

En este campo aparecen varias fuentes de incertidumbre. Un agente puede no saber exactamente cuál es el estado del entorno ni qué consecuencias tendrá una acción. También puede desconocer qué harán los demás agentes, qué objetivos persiguen o qué información tienen disponible. A esto se suma la incertidumbre sobre sus modelos mentales: si razonan de forma estratégica, si imitan, si aprenden, si siguen una heurística o si se comportan de forma inesperada. Además, en algunos casos, interesa separar entre una simple correlación y el efecto real de una acción, y en juegos repetidos también aparece incertidumbre temporal, porque las estrategias pueden cambiar con la experiencia entrando un nuevo factor condicionante, el usuario.

4. Análisis de los cinco trabajos principales

4.1 Koller y Milch: Multi-agent influence diagrams for representing and solving games

Koller, D., & Milch, B. (2003). *Multi-agent influence diagrams for representing and solving games. Games and Economic Behavior*, 45(1), 181-221.

Koller y Milch son una de las referencias principales en este campo. Su propuesta consiste en usar diagramas de influencia multiagente, MAIDs, para representar juegos entre varios agentes. Estos modelos aparecen como alternativa a las representaciones clásicas de la teoría de juegos, como la forma normal o la forma extensiva. Aunque esas representaciones son útiles matemáticamente, muchas veces esconden su estructura real del problema: qué variables dependen del azar, qué decisiones toma cada agente, qué utilidad obtiene cada uno, qué información tiene disponible y/o qué dependencias existen entre variables.

Un MAID puede entenderse como una extensión de las redes bayesianas y de los diagramas de influencia al caso multiagente del mismo. Su grafo incluye nodos de azar, nodos de decisión y nodos de utilidad. Las aristas que llegan a nodos de azar o de utilidad representan dependencias probabilísticas o funcionales, mientras que las aristas que llegan a nodos de decisión indican qué información conoce el agente cuando debe elegir una acción.

El modelo, también puede tener una interpretación causal si las aristas se entienden como relaciones de influencia directa. Aun así, la aportación principal del trabajo no es solo causal, sino sobre todo estratégica y computacional: permite representar juegos no cooperativos de forma más compacta y aprovechar la estructura del grafo para calcular soluciones con menor coste.




Figura 1. MAID "Tree Killer" de Koller y Milch: El grafo representa la interacción estratégica entre Alice y Bob mediante variables de azar, decisiones y utilidades. Las flechas muestran dependencias probabilísticas, relaciones de información y efectos sobre las utilidades de cada agente. Adaptado de Koller y Milch (2003).

Una idea clave del artículo en sí, es la relevancia estratégica. Una decisión es estratégicamente relevante para otra cuando el agente necesita tenerla en cuenta para optimizar su propia regla de

decisión. Para detectar esta correlación, los autores introducen el criterio gráfico s-reachability. A partir de él construyen un grafo de relevancia, que permite dividir un juego grande en partes más pequeñas y calcular equilibrios de Nash aprovechando esa descomposición.

Los parámetros del modelo, como las probabilidades condicionales y las funciones de utilidad, los define el modelador. Por tanto, no es un sistema que aprenda mientras se ejecuta, sino un modelo estático con una estructura y unos parámetros fijados previamente. La evaluación del trabajo cohesiona análisis teórico y ejemplos computacionales. En ejemplos como “Road”, los autores muestran que descomponer el juego según su estructura puede reducir de forma importante el coste de cálculo.

La principal limitación es que esta ventaja depende de que el grafo pueda descomponerse de forma útil. Si las decisiones están muy conectadas entre sí y forman una única componente fuertemente conectada, el algoritmo tiene que resolver prácticamente el juego completo. En ese caso, se pierde buena parte de la mejora computacional que ofrecen los MAIDs.

4.2 Gal y Pfeffer: Networks of Influence Diagrams

Gal, Y., & Pfeffer, A. (2008). Networks of influence diagrams: A formalism for representing agents' beliefs and decision-making processes. Journal of Artificial Intelligence Research, 33, 109-147.

Gal y Pfeffer parten de la idea de los MAIDs, pero la masifican para representar algo más complejo: agentes que no solo toman decisiones, sino que también tienen modelos mentales sobre otros agentes. En un entorno pseudo controlado o abierto, un agente no siempre sabe cómo razonan los demás, qué información tienen, si son racionales o si simplemente siguen una heurística. Para recoger este tipo de situaciones, los autores proponen las Networks of Influence Diagrams, o NIDs.

Un NID puede entenderse como una red de modelos mentales. Cada uno de esos modelos puede representarse mediante un MAID, y además puede incluir creencias sobre los modelos que están usando otros agentes de forma computacional. Esto permite representar razonamientos recursivos del tipo “yo creo que tú crees que yo creo...”, algo muy útil cuando se quiere modelar teoría de la mente o razonamiento estratégico entre agentes.

La estructura del grafo conecta distintos modelos posibles. Dentro de cada estructura se representa un MAID, mientras que las conexiones entre estas estructuras indican qué modelo cree un agente que está utilizando otro. Con esto, el objetivo no es solo calcular cuál sería la estrategia óptima de un agente, sino también diferenciar entre lo que el agente debería hacer según su modelo y lo que realmente se espera que haga.




Figura 2. NID aplicado a RoShamBo: El grafo muestra distintos modelos mentales conectados entre sí, desde el modelo principal (Top-level) hasta el modelo automático (Automaton). Esta estructura permite representar niveles de razonamiento sobre qué cree o anticipa cada agente. Adaptado de Gal y Pfeffer (2008).

A diferencia de otros enfoques más estáticos, en este trabajo sí aparece aprendizaje durante la ejecución. En la aplicación RoShamBo, el sistema utiliza el historial de jugadas para actualizar sus creencias sobre el modelo que sigue el oponente. Para ello emplea una versión online del algoritmo EM adaptada a NIDs.

La evaluación se realiza en un dominio de modelado de oponentes basado en piedra, papel o tijera. Los autores comparan el agente basado en NIDs con programas de una competición automática de RoShamBo. Los resultados muestran que representar explícitamente creencias y niveles de razonamiento puede mejorar el rendimiento frente a estrategias que no se conocen de antemano, siendo entonces su aplicación, razonamiento recursivo entre agentes, como que Bob anticipe qué modelo está usando Alice o cómo Alice podría responder a las expectativas de Bob.

La principal limitación es que el coste computacional puede crecer bastante cuando aumentan el número de modelos mentales y los niveles de razonamiento. Además, el sistema depende de que los modelos incluidos sean suficientemente representativos. Si el oponente se comporta de una forma que no encaja bien en ninguno de esos modelos, el aprendizaje queda acotado y el agente puede interpretar mal la estrategia.

4.3 A Causal Model of Theory-of-Mind in AI Agents

Anonymous Author(s). (2024). *A Causal Model of Theory-of-Mind in AI Agents*. Submitted to the 38th Conference on Neural Information Processing Systems (NeurIPS 2024).

Este estudio lleva la idea de los MAIDs a un contexto más actual, el de agentes de IA capaces de razonar sobre otros agentes. La idea principal es que la agencia no consiste solo en perseguir objetivos, sino que se vuelve mucho más compleja cuando un sistema autónomo interactúa con humanos u otras IAs. En esos casos, el agente necesita razonar sobre creencias, intenciones e información que no controla directamente.

El artículo parte de una limitación importante de los MAIDs tradicionales. Basicamente, estos modelos asumen que todos los agentes comparten el mismo modelo correcto del mundo y de las creencias de los demás. En escenarios reales, esta suposición es demasiado fuerte. Los agentes pueden tener una información incompleta, creencias equivocadas, modelos incompatibles entre sí o no compartir un prior común.

Para representar mejor estos casos, el trabajo propone los MAIDs con información incompleta, o II-MAIDs. Estos modelos mantienen la estructura básica de los MAIDs, con variables de azar, decisiones y utilidades, pero añaden jerarquías explícitas de creencias subjetivas. De esta forma, el modelo puede representar no solo lo que ocurre en el entorno, sino también lo que cada agente cree sobre el entorno y sobre los demás. Además, si las aristas se interpretan como relaciones de influencia directa, el modelo también puede entenderse como un juego causal.




Figura 3. Ejemplo de MAID aplicado a la evaluación de una IA: El grafo muestra dos variantes de evaluación: una relacionada con la honestidad del sistema y otra con sus capacidades peligrosas. En ambos casos se representa la interacción entre la IA y el humano que decide si desplegarla. Adaptado de *A Causal Model of Theory-of-Mind in AI Agents* (2024).

El razonamiento temporal aparece de forma parcial, ya que el artículo relaciona los II-MAIDs con juegos dinámicos de información incompleta. En el ejemplo de seguridad de IA se observa una secuencia clara: el sistema tiene ciertas capacidades, muestra un comportamiento durante una evaluación y después un humano decide si desplegarlo o no.

Se trata de un trabajo principalmente teórico. Los parámetros se definen formalmente mediante distribuciones condicionales y funciones de utilidad, pero no se aprenden a partir de una base de datos. La evaluación también es teórica: el artículo presenta definiciones, resultados formales y ejemplos que muestran la relación entre los II-MAIDs y los juegos dinámicos de información incompleta sin prior común.

Una limitación importante es que, aunque el marco permite definir conceptos de equilibrio, estos pueden ser difíciles de identificar o utilizar en la práctica. El modelo es muy expresivo, pero esa misma generalidad puede hacerlo difícil de manejar computacionalmente cuando se aplique con agentes reales.

4.4 Kearns, Littman y Singh: Graphical Models for Game Theory

Kearns, M., Littman, M. L., & Singh, S. (2001). *Graphical Models for Game Theory*. *Proceedings of UAI 2001*.

Kearns, Littman y Singh se centran en un problema muy concreto: cómo representar juegos con muchos agentes sin que el tamaño del modelo crezca de forma exponencial. En la forma normal de la teoría de juegos, hay que especificar los gastos de cada jugador para todas las combinaciones posibles de acciones. Cuando el número de agentes aumenta, esta representación se vuelve rápidamente intratable.

Para resolverlo, los autores proponen juegos gráficos. En este tipo de modelo, cada jugador se representa como un nodo de un grafo no dirigido, y su utilidad depende solo de su propia acción y de las acciones de sus vecinos. Así pues, el juego global se entiende como un conjunto de interacciones locales, en lugar de como una relación completa entre todos los jugadores.

Esta manera de ver el problema, encaja especialmente bien en sistemas donde las relaciones son locales, como redes de ordenadores, organizaciones, mercados regionales o sistemas multiagente distribuidos. El grafo no debe interpretarse como una red causal en sentido estricto, sino, como una estructura de dependencia estratégica pues, muestra qué agentes influyen directamente en la utilidad de cada jugador.




Figura 4. El grafo muestra una estructura de interacción local entre jugadores. Cada nodo representa un agente y las conexiones indican qué otros agentes influyen directamente en su utilidad. Adaptado de Kearns, Littman y Singh (2001).

El trabajo se centra en juegos de una sola etapa, por lo que no incluye razonamiento temporal explícito. Los parámetros del modelo son las matrices locales de utilidad. Estas matrices se asumen conocidas o se generan artificialmente en los ejemplos utilizados por los autores.

La aportación principal está en los algoritmos para calcular equilibrios de Nash en juegos gráficos con estructura de árbol, o en grafos que pueden transformarse en árbol mediante pocas fusiones de vértices. La idea es parecida a la que se usa en redes bayesianas: aprovechar la estructura del grafo para hacer cálculos locales y después combinar la información.

La evaluación es principalmente teórica. Los autores analizan la complejidad del problema y dan garantías de corrección para ciertas clases de grafos. La principal limitación es que estas ventajas dependen mucho de la estructura del grafo. Si el grafo es denso o tiene una estructura muy compleja, el ahorro computacional disminuye y el problema vuelve a ser difícil de resolver.

4.5 Vickrey y Koller: Multi-Agent Algorithms for Solving Graphical Games

Vickrey, D., & Koller, D. (2002). Multi-Agent Algorithms for Solving Graphical Games. Proceedings of AAAI-02.

Vickrey y Koller continúan la línea de los juegos gráficos, pero se centran más en la parte algorítmica. Su objetivo es encontrar equilibrios aproximados en sistemas multiagente de forma más eficiente. El problema inicial es doble. Por un lado, los algoritmos clásicos para calcular equilibrios suelen ser muy costosos, por otro, muchos de ellos son centralizados, es decir, necesitan que toda la información de pagos esté disponible en un único sistema de cálculo.

El trabajo utiliza juegos gráficos con interacción local. La idea es que cada agente no tenga que comunicarse con todos los demás, sino, sólo con aquellos con los que interactúa directamente. Esto permite plantear métodos más distribuidos y escalables, siempre que la red de interacción no sea demasiado densa.

Los autores proponen dos técnicas principales. La primera es un método de hill-climbing que optimiza una función global relacionada con el arrepentimiento de los agentes. La segunda se basa en satisfacción de restricciones, discretizando el espacio de estrategias. En estos 2 casos, el objetivo es encontrar equilibrios aproximados aprovechando la estructura local del grafo.

El modelo no aprende en el sentido habitual de aprendizaje automático. El juego se considera dado de antemano, con sus matrices locales de utilidad, y los algoritmos funcionan como procedimientos iterativos para buscar perfiles de estrategia estables. En los experimentos, los autores utilizan juegos generados aleatoriamente, variando el número de agentes y la densidad de interacción.




Figura 5. Representación local de un juego gráfico: La figura muestra una estructura sencilla de interacción entre nodos y las tablas utilizadas por el algoritmo para propagar información local. Adaptado de Vickrey y Koller (2002).

La evaluación es experimental. El artículo analiza juegos aleatorios, road games y estructuras de anillo, comparando tanto el tiempo de ejecución como la calidad del equilibrio aproximado obtenido. Los resultados muestran que estos métodos pueden abordar juegos de mayor tamaño que enfoques anteriores, siempre que las interacciones sigan siendo suficientemente locales.

La principal limitación es que el rendimiento depende mucho de la densidad del grafo y de cómo se discretiza el espacio de estrategias, la estructura previa como con los hiperparámetros podríamos decir. Si la red de interacción es muy densa, o si la discretización es demasiado fina, el coste computacional puede aumentar bastante. Además, al trabajar con equilibrios aproximados, se acepta cierto margen de error respecto al equilibrio exacto.

5. Referencias de apoyo teórico

Además de los cinco trabajos principales, se han utilizado referencias de apoyo para situar el análisis, algunas expuestas en este documento (las más correlacionadas al contexto del trabajo) y otras que no. Los textos de teoría de juegos epistémica de Dekel y Siniscalchi, y de Perea, ayudan a explicar por qué son importantes las creencias de primer orden, las creencias de orden superior, las jerarquías de creencias y la racionalidad común. Estos conceptos no son MGPs en sí mismos, pero proporcionan el marco conceptual necesario para entender NIDs e II-MAIDs.

La referencia sobre LIMIDs también resulta útil como apoyo técnico. Los diagramas de influencia de memoria limitada relajan supuestos clásicos como la regularidad y el no-forgetting (el agente recuerda sus anteriores decisiones), permitiendo modelar situaciones donde las decisiones no se condicionan a toda la historia disponible. Aunque no son el núcleo del análisis multiagente, ayudan a entender cómo los diagramas de influencia pueden adaptarse a problemas de decisión más realistas y computacionalmente complejos.

6. Comparación general

Los cinco trabajos forman una progresión bastante coherente. Koller y Milch ofrecen una representación general para juegos multiagente mediante MAIDs. Kearns, Littman y Singh se centran en la estructura local de los juegos gráficos. Vickrey y Koller desarrollan algoritmos distribuidos para resolver esos juegos gráficos de forma aproximada. Gal y Pfeffer añaden una capa epistémica mediante NIDs, permitiendo representar modelos mentales y creencias sobre otros agentes. Finalmente, A Causal Model of Theory-of-Mind in AI Agents lleva esta línea hacia la teoría de la mente en agentes de IA, la información incompleta y el razonamiento causal.

La diferencia clave entre MAIDs y juegos gráficos está en el tipo de estructura que priorizan. Los MAIDs representan explícitamente azar, decisiones, información y utilidades. Los juegos gráficos, en cambio, priorizan la localidad de las interacciones entre jugadores. Los NIDs añaden un nivel adicional pues, no solo representan qué hacen los agentes, sino qué modelo cree un agente que está usando otro. Los II-MAIDs extienden esta idea hacia creencias subjetivas e información incompleta.

En cuanto al aprendizaje, la mayoría de los modelos son estáticos. La excepción más clara es Gal y Pfeffer, donde el agente basado en NIDs actualiza parámetros online en el dominio de RoShamBo. Respecto a la temporalidad, Kearns et al. y Vickrey y Koller se centran principalmente en juegos de una etapa, Koller y Milch pueden representar secuencias de decisiones, Gal y Pfeffer incorporan temporalidad en juegos repetidos y el artículo sobre teoría de la mente conecta su modelo con juegos dinámicos de información incompleta.

Trabajo	Modelo	Temporalidad	Aprende	Evaluación	Principal limitación
Koller & Milch	MAID	Parcial	No	Teórica / computacional	Depende de la descomposición
Gal & Pfeffer	NID	Sí	Sí, online	RoShamBo	Modelos mentales predefinidos
II-MAIDs	MAID incompleto / causal	Sí, dinámico	No	Teórica	Difícil solución práctica
Kearns et al.	Juego gráfico	No	No	Teórica	Grafos densos
Vickrey & Koller	Juego gráfico	Iterativa	No	Experimental	Aproximación / discretización

Tabla 2. Resumen esquematizado de los apartados del punto 4.

7. Ventajas frente a otras técnicas

Los MGPs tienen varias ventajas frente a representaciones clásicas de teoría de juegos y frente a técnicas puramente estadísticas o neuronales. La más importante es la interpretabilidad: permiten ver qué variables intervienen, qué decisiones existen, qué información observa cada agente y qué utilidades se están optimizando.

También permiten separar con claridad azar, decisión, utilidad e información. Esta separación es útil cuando se quiere explicar por qué un agente actúa de determinada manera y cómo cambiaría su decisión si cambiase la información disponible. Además, cuando el grafo es disperso o tiene estructura local, estos modelos pueden reducir el coste computacional frente a representaciones planas. Sin embargo, frente a redes neuronales profundas, estos modelos son menos potentes para aprender patrones a partir de grandes volúmenes de datos, pero son más adecuados cuando se necesita razonamiento explícito sobre agencia, intención, utilidad, información e incertidumbre.

8. Limitaciones y posibles mejoras

Además de las limitaciones planteadas por los autores, visualizamos varias dificultades prácticas. La primera es el tiempo necesario para construir estos modelos. Definir correctamente nodos, dependencias, probabilidades condicionales, utilidades y modelos mentales puede requerir mucho trabajo previo. En sistemas con muchos agentes, esta fase de modelado puede ser lenta y costosa. Por decirlo de forma más sencilla, es más fácil decirlo que hacerlo.

Otra dificultad en relación a la anterior, es la implementación. Aunque los modelos son claros desde un punto de vista teórico, llevarlos a sistemas reales no es inmediato. En muchas aplicaciones puede resultar más sencillo usar reglas heurísticas, árboles de decisión, simulaciones basadas en agentes, aprendizaje por refuerzo multiagente o modelos de lenguaje ajustados mediante prompts.

También existe un problema de escalabilidad. Cuando aumenta el número de agentes, decisiones, niveles de creencias o dependencias, el modelo puede crecer rápidamente, pues el aumento de trabajo por agente es exponencial. Si todos los agentes dependen de todos, se pierde buena parte de la ventaja de la representación gráfica.

Una mejora prometedora sería combinar estos modelos con LLMs. Los modelos de lenguaje podrían ayudar a estimar modelos mentales, inferir intenciones a partir de conversaciones, resumir historiales de interacción o proponer estructuras iniciales del grafo. Esto haría que, sin tener en cuenta el número de agentes, trabajasen con interacciones complejas, porque el LLM podría resumir el contexto y transformar información poco estructurada en elementos útiles para el modelo gráfico. Así, el modelo gráfico aportaría la parte formal e interpretable, mientras que el LLM ayudaría a manejar información textual, ambigua o difícil de convertir manualmente en probabilidades, utilidades o relaciones entre variables.

También sería interesante aplicar estos modelos a debates entre IAs. Se podrían diseñar agentes con posiciones distintas y representar qué cree cada uno, qué argumentos espera del otro y cómo cambia su postura tras cada intervención. Esto permitiría estudiar no solo la respuesta final, sino la evolución del razonamiento durante la interacción.

Otra posibilidad sería incorporar memoria dinámica y aprendizaje continuo, básicamente todas las variedades y extensiones de los modelos LLM. En interacciones reales, los agentes observan patrones, recuerdan decisiones previas y corrigen creencias. Un sistema capaz de actualizar probabilidades, utilidades estimadas o modelos mentales a partir de nuevas observaciones sería más flexible y menos dependiente de parámetros fijados manualmente.

Por último, considero importante que estas interacciones sean lo más visuales posible. Una interfaz que muestre agentes, creencias, decisiones, utilidades e incertidumbre ayudaría a depurar modelos y también tendría valor educativo, porque permitiría explicar conceptos complejos como teoría de la mente, racionalidad limitada o creencias de segundo orden mediante diagramas interactivos. Tal y como trabajar de código directo a notebooks con celdas más visuales.

9. Conclusión

El análisis nos ha mostrado que los MGPs son una herramienta especialmente adecuada para estudiar interacciones entre agentes inteligentes. A diferencia de los modelos puramente predictivos, estos formalismos permiten representar decisiones, incertidumbre, utilidades, información disponible y creencias sobre otros agentes.

Los MAIDs proporcionan una base sólida para representar juegos multiagente con estructura explícita. Los juegos gráficos muestran cómo explotar interacciones locales para escalar a sistemas con muchos agentes. Los algoritmos de Vickrey y Koller muestran que es posible buscar equilibrios aproximados mediante comunicación local. Los NIDs añaden una dimensión clave para la IA, la representación de modelos mentales y creencias recursivas. Finalmente, los II-MAIDs conectan esta línea con la teoría de la mente, la información incompleta y la seguridad de sistemas de IA cada vez más autónomos, tal y como resumimos en el apartado 6.

En conjunto, estas referencias nos muestran que los MGPs no sirven únicamente para razonar sobre incertidumbre en sentido general. También nos dan un lenguaje formal para estudiar agencia, racionalidad, anticipación estratégica y formas de interacción entre inteligencias artificiales.

Referencias bibliográficas

- Anonymous Author(s). (2024). A Causal Model of Theory-of-Mind in AI Agents. Submitted to the 38th Conference on Neural Information Processing Systems (NeurIPS 2024).
<https://openreview.net/pdf?id=ASA2jdKtf3>
- Dekel, E., & Siniscalchi, M. (2015). Epistemic game theory. En P. Young & S. Zamir (Eds.), *Handbook of Game Theory with Economic Applications* (Vol. 4, pp. 619-702). North-Holland.
<https://cet.econ.northwestern.edu/dekel/pdf/epistemic-game-theory.pdf>
- Gal, Y., & Pfeffer, A. (2008). Networks of influence diagrams: A formalism for representing agents' beliefs and decision-making processes. *Journal of Artificial Intelligence Research*, 33, 109-147.
<https://arxiv.org/pdf/1401.3426>
- Kearns, M., Littman, M. L., & Singh, S. (2001). Graphical models for game theory. *Proceedings of the 17th Conference on Uncertainty in Artificial Intelligence (UAI)*.
<https://www.cis.upenn.edu/~mkearns/papers/graphgames.pdf>
- Khaled, A., Hansen, E. A., & Yuan, C. (2013). *Solving Limited-Memory Influence Diagrams Using Branch-and-Bound Search*. En *Proceedings of the Twenty-Ninth Conference on Uncertainty in Artificial Intelligence (UAI 2013)*, 331-340. <https://www.auai.org/uai2013/prints/papers/199.pdf>
- Koller, D., & Milch, B. (2001). Multi-agent influence diagrams for representing and solving games. *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*.
<https://ai.stanford.edu/~koller/Papers/Koller+Milch:IJCAI01.pdf>
- Koller, D., & Milch, B. (2003). Multi-agent influence diagrams for representing and solving games. *Games and Economic Behavior*, 45(1), 181-221. DOI: 10.1016/S0899-8256(02)00544-4
- Perea, A. (2021). Epistemic game theory. En M. Knauff & W. Spohn (Eds.), *The Handbook of Rationality*. The MIT Press. https://epicenter.name/Perea/Papers/581-93313_ch42_1P.pdf
- Vickrey, D., & Koller, D. (2002). Multi-Agent Algorithms for Solving Graphical Games. *Proceedings of the 18th National Conference on Artificial Intelligence (AAAI-02)*.
<https://cdn.aaai.org/AAAI/2002/AAAI02-053.pdf>